



Trabajo de Fin de Grado

Prototipo para la Clasificación Automática de Discurso de Odio y Sarcasmo

Prototypes for the Automatic Classification of Hate Speech and Sarcasm

Adrián Tomás Herrera Darias

La Laguna, 8 de julio de 2026

Este documento incorpora firma electrónica, y es copia auténtica de un documento electrónico archivado por la ULL según la Ley 39/2015.
Su autenticidad puede ser contrastada en la siguiente dirección <https://sede.ull.es/validacion/>

Identificador del documento: 9012057 Código de verificación: bYITPkPb

Firmado por: Adrián Tomás Herrera Darias UNIVERSIDAD DE LA LAGUNA	Fecha 08/07/2026 19:10:41
Dagoberto Castellanos Nieves UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:28:28
Luis García Forte UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:31:30

D. **Luis García Forte**, con N.I.F. 45.445.535-L profesor asociado de la universidad, adscrito al Departamento de Ingeniería Informática y de Sistemas de la Universidad de La Laguna, como tutor.

D. **Dagoberto Castellanos Nieves**, con N.I.F. 79.234.766-L profesor titular de la universidad, adscrito al Departamento de Ingeniería Informática y de Sistemas de la Universidad de La Laguna, como cotutor.

CERTIFICAN

Que la presente memoria titulada:

"Prototipos para la Clasificación Automática de Discurso de Odio y Sarcasmo"

Ha sido realizada bajo su dirección por D. **Adrián Tomás Herrera Darías**, con N.I.F. 43.836.375-P

Y para que así conste, en cumplimiento de la legislación vigente y a los efectos oportunos, firman la presente en La Laguna a 8 de julio de 2026

Este documento incorpora firma electrónica, y es copia auténtica de un documento electrónico archivado por la ULL según la Ley 39/2015.
Su autenticidad puede ser contrastada en la siguiente dirección <https://sede.ull.es/validacion/>

Identificador del documento: 9012057 Código de verificación: bYITPkPb

Firmado por: Adrián Tomás Herrera Darías UNIVERSIDAD DE LA LAGUNA	Fecha 08/07/2026 19:10:41
Dagoberto Castellanos Nieves UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:28:28
Luis García Forte UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:31:30

Agradecimientos

A Andrea, por estar siempre ahí, en los momentos fáciles y, sobre todo, en los difíciles. Por ser un gran apoyo y siempre darme fuerza para seguir mejorando como profesional y persona. A mis tutores por su ayuda y paciencia durante el proceso de esta investigación.

Este documento incorpora firma electrónica, y es copia auténtica de un documento electrónico archivado por la ULL según la Ley 39/2015.
Su autenticidad puede ser contrastada en la siguiente dirección <https://sede.ull.es/validacion/>

Identificador del documento: 9012057 Código de verificación: bYITPkPb

Firmado por: Adrián Tomás Herrera Darias UNIVERSIDAD DE LA LAGUNA	Fecha 08/07/2026 19:10:41
Dagoberto Castellanos Nieves UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:28:28
Luis García Forte UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:31:30

Licencia




© Esta obra está bajo una licencia de Creative Commons
Reconocimiento-NoComercial-SinObraDerivada 4.0 Internacional.

Este documento incorpora firma electrónica, y es copia auténtica de un documento electrónico archivado por la ULL según la Ley 39/2015.
Su autenticidad puede ser contrastada en la siguiente dirección <https://sede.ull.es/validacion/>

Identificador del documento: 9012057 Código de verificación: bYITPkPb

Firmado por: Adrián Tomás Herrera Darias UNIVERSIDAD DE LA LAGUNA	Fecha 08/07/2026 19:10:41
Dagoberto Castellanos Nieves UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:28:28
Luis García Forte UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:31:30



Este documento incorpora firma electrónica, y es copia auténtica de un documento electrónico archivado por la ULL según la Ley 39/2015. Su autenticidad puede ser contrastada en la siguiente dirección https://sede.ull.es/validacion/	
Identificador del documento: 9012057	Código de verificación: bYITPkPb
Firmado por: Adrián Tomás Herrera Darias UNIVERSIDAD DE LA LAGUNA	Fecha 08/07/2026 19:10:41
Dagoberto Castellanos Nieves UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:28:28
Luis García Forte UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:31:30

Índice general

1. Introducción	1
1.1. Conceptos básicos	1
1.2. Estado actual	3
1.3. Objetivos	4
2. Tecnologías Principales	5
2.1. Tecnologías y herramientas principales	5
2.2. Modelos seleccionados	8
2.2.1. Introducción a los Modelos	8
2.2.2. Modelos Relevantes	8
2.2.3. Selección Trimodal	10
3. Experimentación	12
3.1. Conjunto de Datos	14
3.1.1. Corpus Cualitativo	14
3.1.2. Corpus de Evaluación Cuantitativa Masiva	15
3.1.3. Corpus Cuantitativo de Toxicidad Nativa	16
3.1.4. Corpus Cuantitativo de Escalabilidad Futura	17
3.2. Características de los corpus	18
3.2.1. Características de Longitud	19
3.2.2. Origen del Vocabulario	20
3.2.3. Formato e infraestructura de Memoria	20
3.2.4. Resumen	21
3.3. Modelos y corpus lingüísticos seleccionados	21
3.3.1. RoBERTa-ES	21
3.3.2. ELECTRA	22
3.3.3. DistilBERT-Multilingual	22
4. Análisis de los resultados	24
4.1. Métricas	24
4.2. Análisis comparativo	26
4.3. Análisis cuantitativo	28
4.3.1. Toxicidad y Odio	28
4.3.2. Ironía	30
4.4. Análisis cualitativo	32

I

Este documento incorpora firma electrónica, y es copia auténtica de un documento electrónico archivado por la ULL según la Ley 39/2015.
Su autenticidad puede ser contrastada en la siguiente dirección <https://sede.ull.es/validacion/>

Identificador del documento: 9012057 Código de verificación: bYITPkPb

Firmado por: Adrián Tomás Herrera Darias UNIVERSIDAD DE LA LAGUNA	Fecha 08/07/2026 19:10:41
Dagoberto Castellanos Nieves UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:28:28
Luis García Forte UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:31:30

4.5. Resultados del análisis	34
5. Conclusiones y líneas futuras	35
6. Conclusions and future work	37
7. Presupuesto	39
7.1. Presupuesto de recursos humanos	39
7.2. Presupuesto material	40
7.3. Presupuesto final	40
A. Proyectos finales y datos obtenidos	41
B. Conjunto de datos y Modelos	42
B.1. Conjuntos de Datos (Datasets)	42
B.2. Modelos de Lenguaje Seleccionados	42

Este documento incorpora firma electrónica, y es copia auténtica de un documento electrónico archivado por la ULL según la Ley 39/2015.
Su autenticidad puede ser contrastada en la siguiente dirección <https://sede.ull.es/validacion/>

Identificador del documento: 9012057 Código de verificación: bYITPkPb

Firmado por: Adrián Tomás Herrera Darías UNIVERSIDAD DE LA LAGUNA	Fecha 08/07/2026 19:10:41
Dagoberto Castellanos Nieves UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:28:28
Luis García Forte UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:31:30

Índice de Figuras

4.1. Evolución de la función de pérdida (Cross-Entropy Loss) en el modelo RoBERTa-ES.	29
4.2. Matriz de confusión normalizada del modelo RoBERTa-ES en el corpus multiclase toxic_es.	30
4.3. Distribución empírica de predicciones del modelo ELECTRA-ES ante el fenómeno del sarcasmo.	31

Este documento incorpora firma electrónica, y es copia auténtica de un documento electrónico archivado por la ULL según la Ley 39/2015.
Su autenticidad puede ser contrastada en la siguiente dirección <https://sede.ull.es/validacion/>

Identificador del documento: 9012057 Código de verificación: bYITPkPb

Firmado por: Adrián Tomás Herrera Darias UNIVERSIDAD DE LA LAGUNA	Fecha 08/07/2026 19:10:41
Dagoberto Castellanos Nieves UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:28:28
Luis García Forte UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:31:30

Índice de Tablas

3.1. Propiedades estructurales de los corpus y Subconjuntos Experimentales.	19
3.2. Parámetros Estructurales y Propiedades Físicas de los Corpora.	21
4.1. Comparativa de Rendimiento en Detección de Sarcasmo (savioruz/id-x-sarcasm).	26
4.2. Comparativa de Rendimiento y Tiempos de Entrenamiento en Entorno Multiclase (toxic_es).	27
4.3. Comparativa Cualitativa de Predicciones sobre la Sonda de Estrés Estereotípica	32
7.1. Presupuesto Personal	39
7.2. Presupuesto de los materiales necesarios	40
7.3. Presupuesto Final	40

Este documento incorpora firma electrónica, y es copia auténtica de un documento electrónico archivado por la ULL según la Ley 39/2015.
Su autenticidad puede ser contrastada en la siguiente dirección <https://sede.ull.es/validacion/>

Identificador del documento: 9012057 Código de verificación: bYITPkPb

Firmado por: Adrián Tomás Herrera Darias UNIVERSIDAD DE LA LAGUNA	Fecha 08/07/2026 19:10:41
Dagoberto Castellanos Nieves UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:28:28
Luis García Forte UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:31:30

Capítulo 1

Introducción

En este proyecto se desarrolla una investigación orientada al diseño e implementación de prototipos para la clasificación automática de texto, con el objetivo de detectar discurso de odio y sarcasmo en mensajes escritos. La motivación principal surge del creciente volumen de contenido generado en redes sociales y plataformas digitales, donde la identificación automática de lenguaje ofensivo o irónico representa un desafío tanto técnico como ético.

Este escenario ha llevado a la implementación de modelos basados en arquitectura Transformer para el procesamiento del lenguaje natural, generando la necesidad de revisar críticamente su habilidad para discernir la sintaxis y la idoneidad frente a entornos altamente complejos. La presente investigación se dirige al examen del funcionamiento de estos clasificadores ante dos desafíos metodológicos extremadamente contrarios: una hostilidad sistemática basada en términos propios y jerga de hablante nativo; por otro lado, la inversión lógica del sarcasmo introducida por el entorno lingüístico incierto motivado por estructuras de origen multilingüe.

Así, la evaluación no limita las métricas de precisión estadísticas comunes, sino que va más allá con el análisis de la fortaleza de los tokenizadores ante el ruido en la distribución de la marca de grupo, choque gramatical transcultural y validez cualitativa de la aseguración de probabilidad de confianza a las muestras que se analizan.

1.1. Conceptos básicos

El desarrollo de una investigación enfocada en el análisis automático del discurso de odio y sarcasmo implica establecer de antemano una variedad de términos cruciales para proporcionar un marco sólido y un punto de partida para este estudio.

Para garantizar una presentación lógica del marco teórico y del método usado en la investigación, se define aquí una colección de conceptos clave con relación al procesamiento del lenguaje y al diseño del procesamiento de datos.

- Procesamiento del lenguaje natural (PLN): Es un subcampo de la informática y la inteligencia artificial, que permite que los ordenadores y dispositivos

digitales reconozcan, comprendan y generen texto y voz mediante la combinación lingüística computacional, junto con el modelo estadístico, machine learning y deep learning.[6]

- Corpus lingüístico y Dataset: Es un gran conjunto de textos que debe reflejar una lengua o su modalidad de la forma más exacta posible y que su representación sea real. El objetivo es representar al lenguaje de la mejor forma posible para que los modelos PLN puedan aprender los patrones necesarios para entender el lenguaje.[2] Como "materia prima" para el aprendizaje automatizado (machine learning), el conjunto de datos de calidad actúa como base sobre la cual se sustenta el entrenamiento, prueba y validación de los algoritmos. Su propósito es suministrar una distribución estadística apropiada del habla humana, proporcionando así la base para que los modelos de inteligencia artificial reconozcan patrones lingüísticos, sintácticos y pragmáticos ocultos para generalizar conocimientos hacia tareas concretas sin generar problemas de ajuste excesivo o bajo.[18] [12]

- Corpus sintético: Conjunto de datos textuales generado artificialmente mediante reglas lingüísticas, algoritmos de generación automática o modelos lingüísticos, con el objetivo de replicar las características léxicas, sintácticas y semánticas de un corpus real existente. En el ámbito del procesamiento del lenguaje natural (PLN), dichos corpus sintéticos sirven como ampliación de conjuntos de datos previos, mejorando la diversidad de ejemplos, la estabilización de clasificaciones escasas y la independencia en la gestión de fuentes etiquetadas manualmente, que requieren una gran inversión económica e intelectual.

El corpus sintético ofrece el plus de proteger el anonimato de los intercambios de información al mantener intactos los textos producidos, aislándolos de conexiones vívidas con datos reales. Sin embargo, la utilidad de un corpus sintético está directamente ligada a su exactitud y fiabilidad en cuanto a la producción y el ajuste a la realidad del dominio donde opera. Una generación pobre o limitada afecta gravemente al corpus, potenciando errores e incluyendo posibles sesgos, lo que reduce la fiabilidad de un modelo y desplaza la eficacia del PLN en aplicaciones prácticas[22].

- Clasificación de texto (Text Classification): La tarea fundamental y transversal dentro del procesamiento del lenguaje natural es la asignación automática de etiquetas categóricas discretas a una unidad textual (frase, párrafo o documento completo) según su contenido semántico.

Dependiendo de la naturaleza de las variables objetivas, la tarea se puede definir bajo un enfoque binario —con sólo dos categorías mutuamente excluyentes, como detección de sarcasmo— o a través de un enfoque multi-clase/multietiqueta, tales como el análisis de sentimiento clásico (positivo, negativo y neutral junto a emojis) o la clasificación de toxicidad con subtipos específicos de hostilidad.

Este documento incorpora firma electrónica, y es copia auténtica de un documento electrónico archivado por la ULL según la Ley 39/2015.
Su autenticidad puede ser contrastada en la siguiente dirección <https://sede.ull.es/validacion/>

Identificador del documento: 9012057 Código de verificación: bYITPkPb

Firmado por: Adrián Tomás Herrera Darias UNIVERSIDAD DE LA LAGUNA	Fecha 08/07/2026 19:10:41
Dagoberto Castellanos Nieves UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:28:28
Luis García Forte UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:31:30

El éxito de esta clasificación reside en la capacidad del modelo para traducir texto no estructurado en representaciones vectoriales densas interpretables por el sistema[1].

- Abstracción por Tuberías (*Pipelines*): Componente arquitectónico avanzado dentro del ecosistema de los *Transformers* diseñado para encapsular y automatizar el flujo de datos secuencial. Su objetivo principal es aislar la complejidad matemática de las operaciones de bajo nivel, unificando en una única infraestructura lineal las fases de preprocesamiento, inferencia matricial y postprocesamiento estadístico[23].

Estos conceptos son importantes para tener una buena base y dar sentido a una investigación como la propuesta.

Las ideas relativas al procesamiento del lenguaje natural y a la clasificación de textos proporcionan el conocimiento básico sobre cómo operan los modelos y cuán capaces son de comprender la complejidad de los datos lingüísticos.

El estudio de los conjuntos de datos (*datasets*) y los corpus sintéticos facilita nuestro entendimiento de la organización y selección de los ejemplos de texto que utilizamos, al mismo tiempo que el concepto de tuberías nos ofrece una perspectiva clara del flujo de trabajo: cómo se ingresa un texto original hasta que se genera una respuesta automatizada.

Por lo tanto, establecer un marco teórico adecuado con estos conceptos permite entender el comportamiento, la lógica y el desarrollo de las pruebas llevadas a cabo.

1.2. Estado actual

El análisis automático del lenguaje natural es una de las áreas de investigación más activas dentro de la inteligencia artificial[10]. Los avances en aprendizaje profundo y en modelos basados en transformadores han permitido desarrollar sistemas capaces de identificar matices lingüísticos, intenciones implícitas y relaciones semánticas complejas. La detección de discurso de odio y sarcasmo es un reto particular dentro de este campo, ya que requiere no solo reconocer patrones superficiales, sino también entender contexto, ironía y elementos culturales.[20, 11].

En el ámbito del discurso de odio, la literatura académica coincide en que el uso de grandes corpus etiquetados y modelos preentrenados como BERT[5], RoBERTa[13] o DistilBERT[19] incrementa de forma significativa la capacidad de detección. Se incorporará una visión más amplia al analizar el riesgo de que estos modelos no solo clasifiquen incorrectamente, sino que generen contenido tóxico o refuercen estereotipos en determinadas condiciones.

Este enfoque resulta especialmente relevante para el trabajo, ya que permite comprender mejor los riesgos asociados al uso de IA en contextos sensibles como son:

- Sesgos en *datasets*: Los corpus suelen contener distribuciones no equilibradas hacia ciertos grupos demográficos, lo que puede sesgar la clasificación.

Este documento incorpora firma electrónica, y es copia auténtica de un documento electrónico archivado por la ULL según la Ley 39/2015.
Su autenticidad puede ser contrastada en la siguiente dirección <https://sede.ull.es/validacion/>

Identificador del documento: 9012057 Código de verificación: bYITPkPb

Firmado por: Adrián Tomás Herrera Darias UNIVERSIDAD DE LA LAGUNA	Fecha 08/07/2026 19:10:41
Dagoberto Castellanos Nieves UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:28:28
Luis García Forte UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:31:30

- Generalización limitada: Los modelos entrenados en un dominio o plataforma tienden a perder rendimiento al aplicarse en otros contextos.
- Detección dependiente del contexto: Frases que parecen ofensivas de forma aislada pueden no serlo dentro de un intercambio conversacional.
- Dificultad para identificar agresiones implícitas: El discurso de odio indirecto, humorístico o contextualizado sigue siendo un reto.

El análisis automático del lenguaje mediante arquitecturas basadas en transformadores ha experimentado avances significativos en la comprensión de estructuras semánticas complejas. No obstante, su eficacia continúa limitada por la naturaleza subjetiva y dependiente del contexto de fenómenos lingüísticos como la ironía y el discurso racista.

Los hallazgos identificados en el estado del arte indican que las estrategias actualmente empleadas presentan limitaciones fundamentales. Entre ellas destacan la transferencia de sesgos a través de los conjuntos de entrenamiento, las dificultades para transferir conocimiento entre dominios distintos y la limitada capacidad para comprender el contexto pragmático de las interacciones.

Esto significa que la creación de sistemas confiables implica superar la simple identificación de patrones, abordar directamente el entorno cultural y las estructuras lingüísticas ocultas que informan nuestro planteamiento. El estudio reciente examina estas cuestiones de forma directa.

1.3. Objetivos

El objetivo principal de esta investigación reside en crear e inspeccionar un marco comparativo a partir de algoritmos de clasificación automatizada basados en aprendizaje profundo con el fin de mejorar la detección de insultos de odio y de burla en diversos conjuntos de datos.

Este trabajo surge del interés y la motivación por aportar soluciones a una necesidad crítica de carácter sociotecnológico: la proliferación de conductas hostiles, discursos amenazantes y fenómenos de polarización en las plataformas digitales actuales. Ante el impacto adverso que el sesgo algorítmico y la toxicidad ejercen sobre la convivencia en los entornos virtuales, se plantea con el firme propósito de asumir la urgencia de investigar, evaluar y optimizar herramientas automatizadas eficaces para mitigar estas dinámicas de desintegración comunitaria.

El TFG aborda esta problemática desde una perspectiva multidimensional, analizando de forma simultánea la detección automática de agresiones verbales implícitas y los desafíos pragmáticos asociados a la ironía y la implicación. La metodología evalúa el rendimiento de los modelos mediante indicadores estadísticos, como la precisión y la matriz de confusión, y analiza su eficiencia computacional en términos de tiempo de procesamiento y coste de cálculo, con el fin de verificar su viabilidad técnica para aplicaciones de monitorización en tiempo real.

Este documento incorpora firma electrónica, y es copia auténtica de un documento electrónico archivado por la ULL según la Ley 39/2015.
Su autenticidad puede ser contrastada en la siguiente dirección <https://sede.ull.es/validacion/>

Identificador del documento: 9012057 Código de verificación: bYITPKPb

Firmado por: Adrián Tomás Herrera Darias UNIVERSIDAD DE LA LAGUNA	Fecha 08/07/2026 19:10:41
Dagoberto Castellanos Nieves UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:28:28
Luis García Forte UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:31:30

Capítulo 2

Tecnologías Principales

En este capítulo se presentan las principales tecnologías, herramientas y modelos con los que se desarrolla la propuesta.

2.1. Tecnologías y herramientas principales

Se realizó un análisis y valoración de las principales tecnologías que se emplean en el desarrollo del proyecto. Las seleccionadas serían las siguientes:

1. **Python:**¹ Python es un lenguaje de programación de alto nivel, interpretado y multiparadigma que admite el paradigma orientado a objetos, la programación imperativa y funcional.

Destaca por su sintaxis limpia y fácil de leer, lo que facilita el desarrollo y la gestión del código. Su gran ecosistema de bibliotecas y herramientas ha hecho que Python sea uno de los lenguajes de programación más utilizados en el desarrollo de software, ciencia de datos, aprendizaje automático, inteligencia artificial y procesamiento del lenguaje natural (PLN).

Se utiliza como el principal lenguaje de programación para el desarrollo del sistema y la integración de las distintas bibliotecas que hemos usado durante la capacitación y evaluación del modelo.

2. **Hugging Face:**² Es una organización y plataforma de código abierto centrada en la inteligencia artificial y el aprendizaje automático.

Ofrece un entorno colaborativo donde desarrollar, compartir y reutilizar modelos preentrenados, conjuntos de datos y aplicaciones relacionadas con el PLN y la IA generativa.

Dispondrá de un repositorio público de modelos y recursos accesibles para tecnologías de vanguardia y la colaboración con investigadores y desarrolladores.

3. **Hugging Face Transformer:**³ Una biblioteca abierta de Hugging Face que

¹<https://www.python.org/>

²<https://huggingface.co/>

³<https://huggingface.co/docs/transformers/main/en/index>

ofrece implementaciones preentrenadas de modelos Transformer para diversas tareas de procesamiento del lenguaje natural, visión por computador, reconocimiento del habla y IA multimodal.

La biblioteca facilita la carga de modelos y tokenizadores, el procesamiento de inferencias, el entrenamiento y el ajuste fino con métodos de alto nivel como el Trainer. Es compatible con PyTorch y TensorFlow y se integra con estos dos para la creación de aplicaciones de LLMs. Esta biblioteca sirve como plataforma para la configuración y el ajuste del modelo base, junto con los procesos de entrenamiento y ajuste fino.

4. **Hugging Face Pipelines:**⁴ Las pipelines son una interfaz de nivel alto integrada en la biblioteca Transformers, diseñada para simplificar la aplicación de modelos preentrenados a distintos tipos de tareas de IA, incluyendo clasificación de textos, creación de textos, traducción automatizada, análisis emocional y respuesta a preguntas.

El objetivo principal es automatizar el preproceso, la tokenización, la ejecución de modelos y el postprocesamiento de los resultados, reduciendo así el grado de complejidad inherente al desarrollo a través de las propuestas que contienen un número bajo de líneas de código. De igual forma, simplifica la gestión de la conexión con hardware apto para el uso, mejorando así la eficiencia de los recursos de CPU y GPU en su empleo.

5. **Google Colab:**⁵ Google Colab (Colaboratory de Google) es un entorno de desarrollo en la nube basado en cuadernos de Jupyter Notebook donde se puede escribir, ejecutar y documentar código principalmente en Python, usando directamente un navegador web, sin necesidad de instalar software ni configuración de dependencias en el dispositivo local.

Un cuaderno combina celdas ejecutables de código con texto, gráficos y resultados numéricos, permitiendo desarrollar, experimentar y documentar proyectos. La plataforma ofrece acceso a recursos de cómputo en la nube, incluyendo CPU, GPU y, en algunos casos, TPU, lo que permite la ejecución de tareas de aprendizaje automático e inteligencia artificial con una mayor carga de trabajo, ya que muchos dispositivos personales no poseen recursos superiores.

La integración de Google Drive permite guardar y gestionar los cuadernos, lo que facilita tanto la colaboración entre los participantes de una misma tarea como la reproductibilidad de la experimentación. En esta investigación, Google Colab ha sido utilizado como entorno de desarrollo e implementación para el fine-tuning del modelo de lenguaje, y aprovecha los recursos de la nube para entrenar la máquina de manera efectiva y sin depender del hardware local.

⁴https://huggingface.co/docs/transformers/main/en/pipeline_tutorial/

⁵<https://colab.research.google.com/>

Este documento incorpora firma electrónica, y es copia auténtica de un documento electrónico archivado por la ULL según la Ley 39/2015.
Su autenticidad puede ser contrastada en la siguiente dirección <https://sede.ull.es/validacion/>

Identificador del documento: 9012057 Código de verificación: bYITPkPb

Firmado por: Adrián Tomás Herrera Darias UNIVERSIDAD DE LA LAGUNA	Fecha 08/07/2026 19:10:41
Dagoberto Castellanos Nieves UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:28:28
Luis García Forte UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:31:30

6. **Google Drive** ⁶ Este servicio es un entorno de almacenamiento en la nube que facilita guardar, organizar y compartir archivos por medio de Internet.

Al integrarse con Google Colab en su versión 1.22.0, se puede acceder de forma nativa a la unidad de almacenamiento remoto dentro del sistema de archivos local del ambiente de ejecución. Esto permite el acceso a datos, modelos, resultados y demás aspectos importantes del desarrollo de cualquier proyecto de un modo más directo. Por otra parte, el uso del almacenamiento de Google Colab es temporal; es decir, al finalizar el entorno de ejecución, se eliminará el almacenamiento de datos, modelos y archivos relacionados.

Esto permite disponer y mantener fiables los datos generados durante todas las etapas de la experimentación sin recurrir a archivos temporales: se utilizó Google Drive en esta investigación para mantener los datos de corpus, el modelo entrenado y los resultados finales del experimento.

7. **PyTorch:** ⁷ PyTorch es un marco de aprendizaje profundo (deep learning) de código abierto creado por Meta AI, que proporciona una gran cantidad de herramientas para diseñar, entrenar y evaluar modelos basados en redes neuronales. Se distingue por usar un grafo dinámico de cómputo, lo que convierte la elaboración, depuración y prueba con modelos complejos en mucho más sencilla. Asimismo, permite acelerar mediante la GPU, reduciendo sustancialmente los tiempos de entrenamiento e inferencia.

Por su versatilidad, sencillez de uso y estrecho intercambio con bibliotecas especializadas como Hugging Face Transformers, PyTorch ha ganado fama entre investigadores y profesionales de aplicaciones en procesamiento del lenguaje natural (PLN), reconocimiento visual y áreas más allá de la inteligencia artificial. En este artículo, PyTorch sirve como plataforma sobre la que se apoya la fase de fine-tuning del modelo de lenguaje.[9]

8. **GitHub:** ⁸ Es una plataforma colaborativa de desarrollo basada en Git, un sistema de control de versiones, que alberga, gestiona y comparte proyectos de software en la nube. Más allá del almacenamiento del código fuente, ofrece herramientas para rastrear los cambios, gestionar las versiones, resolver problemas, documentar proyectos y colaborar entre múltiples desarrolladores a través de ramas (branches) y solicitudes de incorporación (pull requests).

GitHub facilita mantener un completo registro histórico del proyecto, fomenta la reproducibilidad de los avances y agiliza la distribución del código. En este estudio, GitHub actúa como repositorio para almacenar el código diseñado y mantener el control de versiones a lo largo de cada etapa de lanzamiento e investigación.

⁶<https://drive.google.com/drive>

⁷<https://pytorch.org/>

⁸<https://github.com/>

2.2. Modelos seleccionados

Para poder hablar de los modelos que utilizamos durante el transcurso del prototipo, debemos primero saber por qué y cómo surgen los modelos del procesamiento del lenguaje, el panorama del arte y los modelos más relevantes y la justificación de la selección trimodal.

2.2.1. Introducción a los Modelos

El procesamiento del lenguaje natural (PLN) sufrió una reorientación en la evolución de modelos, pasando del paradigma RNN (redes neuronales recurrentes) y LSTM (memoria corta y a largo plazo) a la arquitectura Transformer, descrita por Vaswani et al. en 2017 [21].

Las arquitecturas previas tenían limitaciones intrínsecas que hacían casi insuperables tareas complejas como la detección de la ironía o el discurso de odio: su naturaleza secuencial impidió el proceso paralelo masivo y sufrían del fenómeno de desvanecimiento del gradiente al analizar dependencias a largo plazo. En entornos de comunicación digital, donde la hostilidad o el doble sentido pueden estar vinculados a la relación entre un primer término de un texto y un punto de finalización, las arquitecturas recurrentes fracasaban con mayor frecuencia.

La implementación del mecanismo de autoatención (self-attention) eliminó la dependencia del procesamiento secuencial [24]. La formulación matemática de las relaciones de relevancia entre todas las palabras de una secuencia realizaba sus cálculos a la vez, y este método permitía a los modelos basados en transformers construir representaciones contextualizadas bidireccionales dinámicas de una profundidad sin parangón. A partir de este logro, surgió el modelo de lenguaje preentrenado grande (PLM)[15].

El primero en destacar fue BERT (Bidirectional Encoder Representations from Transformers). Su innovación fue mostrar que la estrategia efectiva implicaba realizar un preentrenamiento autosupervisado masivo con texto genérico (predicción de palabras desconocidas) y, tras ello, un ajuste fino específico para tareas altamente especializadas (técnicas downstream), tales como la clasificación de texto y la identificación de toxicidad.

2.2.2. Modelos Relevantes

A partir del éxito disruptivo de la arquitectura Transformer, la investigación académica ha divulgado nuevas direcciones de técnicas de entrenamiento, dividiendo las formas de aprendizaje supervisado y autosupervisado. Esto ha creado un entorno ecológico que ha dado lugar a las arquitecturas principales que forman el panorama actual del procesamiento del lenguaje natural.

Desde el enfoque de la modality data, todos los modelos analizados en esta sección están clasificados de manera estricta como arquitecturas monomodales, ya que sus espacios vectoriales y matrices de atención han sido optimizados exclusivamente para el procesamiento y modelado de secuencias de texto plano y no tienen capas de fusión para estímulos visuales o auditivos.

Este documento incorpora firma electrónica, y es copia auténtica de un documento electrónico archivado por la ULL según la Ley 39/2015.
Su autenticidad puede ser contrastada en la siguiente dirección <https://sede.ull.es/validacion/>

Identificador del documento: 9012057 Código de verificación: bYITPkPb

Firmado por: Adrián Tomás Herrera Darias UNIVERSIDAD DE LA LAGUNA	Fecha 08/07/2026 19:10:41
Dagoberto Castellanos Nieves UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:28:28
Luis García Forte UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:31:30

A continuación aparecen las características de los modelos más influyentes del estado del arte, fusionando aspectos de la literatura científica con las modificaciones específicas introducidas en el presente trabajo:

BERT: Es el elemento esencial y el estándar reconocido por la comunidad científica. Está organizado según el modelo de encoder de los transformers.

Sus características incluyen una codificación bidireccional avanzada que capta tanto el contexto derecho como el izquierdo de una palabra. Además, se vuelve desproporcionadamente costoso en términos de procesamiento debido a la baja eficiencia en el enmascaramiento activo, así como al alto consumo de máquinas requerido para su optimización.[5]

RoBERTa: Es un sistema monomodal inspirado en el Encoder de BERT que introduce importantes mejoras en el proceso de entrenamiento inicial. La versión elimina la tarea secundaria de pronóstico de la oración siguiente (Next Sentence Prediction) y establece un sistema de enmascaramiento dinámico (Dynamic Masking) para gran parte del texto. Al darle preferencia al rango de significado de las características, extrayendo sin perturbar la estructura básica, RoBERTa se mantiene en el primer lugar en la lista de clasificadores de alto rendimiento de lenguaje natural. [13]

ELECTRA: Es un sistema monomodal que rompe con los modelos tradicionales de enmascaramiento lingüístico. En su lugar, aplica un enmascaramiento de tokens según una serie de posibilidades (Token Masking) en lugar de usar un mecanismo denominado Detección de Tokens Reemplazados (Replaced Token Detection o RTD). Cuando se debe evaluar si cada palabra de la secuencia ha sido sustituida por otra palabra generada en forma alternativa, el modelo ajusta todas sus variables en cada paso de la iteración. Además, esto contribuye al mejor desempeño computacional y ayuda a detectar disparidades probables y inconsistencias de texto.[4]

BETO: Una adaptación directa de BERT entrenado únicamente con una amplia gama de corpus en español. Aunque puso las bases para el PLN hispanohablante, faltan las optimizaciones de parámetros y la ingeniería de tokenización que se introdujeron en las arquitecturas posteriores.[3]

GPT: Un modelo monomodal centrado exclusivamente en el decoder (decodificador) del transformer. Es actualmente el líder absoluto en campos como la generación de texto autorregresivo y el desarrollo de modelos conversacionales avanzados. No obstante, su arquitectura de procesamiento unidireccional puede limitar su desempeño eficiente, así como su rendimiento de eficiencia computacional cuando se le aplica a tareas de clasificación semántica precisa y al etiquetado estricto.[16]

DistilBERT: Un modelo monomodal de tipo Encoder creado siguiendo los principios de diseño centrados en la ingeniería de optimización y en la accesibilidad. Implementó la técnica de aprendizaje por destilación del conocimiento (Knowledge Distillation) para compactar el tamaño de BERT en un 40 %, pero preservando alrededor del 97 % de su función interpretativa lingüística. Al eliminar las capas de atención de manera geométrica y aligerar los pesos de los parámetros, se po-

Este documento incorpora firma electrónica, y es copia auténtica de un documento electrónico archivado por la ULL según la Ley 39/2015.
Su autenticidad puede ser contrastada en la siguiente dirección <https://sede.ull.es/validacion/>

Identificador del documento: 9012057 Código de verificación: bYITPkPb

Firmado por: Adrián Tomás Herrera Darias UNIVERSIDAD DE LA LAGUNA	Fecha 08/07/2026 19:10:41
Dagoberto Castellanos Nieves UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:28:28
Luis García Forte UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:31:30

siciona como el modelo estandarizado para uso en entornos de producción que requieren limitaciones estrictas sobre la memoria VRAM y la velocidad de procesamiento de inferencia.[19]

T5: Modelo monomodal híbrido que combina las capacidades del encoder y el decoder en un enfoque text-to-text.

Por tanto, posee excelentes propiedades para la traducción y la resumificación automática, pero requiere muchos más parámetros e hiperparámetros de los necesarios. Esto hace que su desempeño operativo sea moderado, con un uso de recursos alto respecto a los modelos codificadores puros, lo que impide que esté bien diseñado para entornos de hardware reducido. [17]

2.2.3. Selección Trimodal

Con respecto a las opciones consideradas en el estudio, se descarta claramente la elección de arquitecturas multimodales complejas y se escoge un enfoque monomodal estructurado que utilice tres arquitecturas: RoBERTa, ELECTRA y DistilBERT. Esta selección fue motivada por razones técnicas de complementación, por la eficiencia en los requisitos de hardware, así como por diversidad metodológica:

RoBERTa

La elección de esta red neuronal, bertin-project/bertin-roberta-base-spanish, está motivada por su avanzada aplicación en modelos de lenguaje nativo. Eliminamos la tarea secundaria Next Sentence Prediction, así como añadimos un enmascaramiento dinámico sobre una enorme cantidad de datos, lo que resulta en un incremento significativo en el procesamiento de caracteres complejos. En nuestra implementación preliminar, actúa como punto de referencia de máxima relevancia lingüística contextual. Su capacidad de identificar detalles complejos es crucial para la extracción de la percepción abstracta de las tendencias y prejuicios generalizados, especialmente cuando estos no se reflejan en un análisis directo.

ELECTRA

La elección de ELECTRA, google/electra-base-discriminator y ChrisZeng/electra-large-discriminator-nli-efl-hateval, surgió de una innovación que mejoró su eficiencia en el aprendizaje. Entrenada como discriminador mediante el análisis de las secuencias para detectar el token de suplantación en lugar de simplemente predecir los huecos, la red tiene que evaluar la probabilidad de cada elemento de la secuencia. Su carácter crítico implica que está preparada para encontrar diferencias estadísticas; un rasgo que, desde una perspectiva metodológica, es ideal para reconocer elementos de humor como el sarcasmo y el doble sentido, donde los giros irónicos alteran la expectativa lógica habitual.

DistilBERT

Utilizar DistilBERT, distilbert/distilbert-base-multilingual-cased, aporta aspectos como viabilidad y optimización de ingeniería al proyecto. En un contexto de entrega de software, factores como costes y limitaciones de hardware (memoria VRAM, tiempo de procesamiento) son relevantes. La incorporación de un modelo comprimido a través del conocimiento se refuerza por ser una dimensión empírica

crucial: puede cuantificar la pérdida de precisión respecto al beneficio en cuanto a velocidad y tamaño reducido, y validar así si el prototipo es escalable para entornos con capacidades computacionales restrictivas.

El enfoque trimodal seleccionado asegura que el prototipo sea evaluado desde tres perspectivas metodológicas en conflictividad: la robustez más amplia (RoBERTa), la agilidad analítica (ELECTRA) y la eficiencia computacional (DistilBERT).

Este documento incorpora firma electrónica, y es copia auténtica de un documento electrónico archivado por la ULL según la Ley 39/2015.
Su autenticidad puede ser contrastada en la siguiente dirección <https://sede.ull.es/validacion/>

Identificador del documento: 9012057 Código de verificación: bYITPkPb

Firmado por: Adrián Tomás Herrera Darias UNIVERSIDAD DE LA LAGUNA	Fecha 08/07/2026 19:10:41
Dagoberto Castellanos Nieves UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:28:28
Luis García Forte UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:31:30

Capítulo 3

Experimentación

En este ensayo experimental se busca evaluar la capacidad predictiva y la resistencia estructural de las arquitecturas respecto a los cambios semánticos generados por plataformas digitales.

Se compara su desempeño en la decodificación del discurso hostil (el discurso de odio) con el proceso de integración del discurso inverso lógico característico del sarcasmo.

Para el flujo metodológico estandarizado en cada fase del experimento, se sigue un pipeline secuencial estricto:

- **Carga y auditoría del corpus:** Inspección profunda de las dimensiones de entrada, estructuras de almacenamiento y distribución probabilística de las clases objetivo.
- **Limpieza y ajuste estructural de etiquetas:** Reconstrucción vectorial de variables objetivo y aislamiento de metadatos corruptos de almacenamiento para garantizar la compatibilidad matricial con los hilos de ejecución concurrentes de la GPU.
- **Tokenización dinámica:** Adaptación del texto mediante esquemas de subpalabras específicos de cada arquitectura, aplicando truncado estricto a un máximo de 512 tokens en pruebas cualitativas y 128 tokens en entrenamientos masivos.
- **Fine-tuning (ajuste fino):** Entrenamiento supervisado, interrumpiendo el proceso en un entorno controlado de dos épocas, utilizando precisión de punto flotante de 16 bits (fp16) para optimizar el uso de VRAM bajo la interfaz Trainer de Hugging Face.
- **Evaluación cruzada y extracción de métricas:** Monitorización de la métrica de accuracy (Exactitud) sobre subconjuntos de prueba independientes (20 %) y registro del tiempo de cómputo empleado en GPU.

A través de su estandarización y estabilización en cuanto al proceso de carga, la limpieza y el proceso de entrenamiento regulares, se asegura que el consumo de

los diferentes conjuntos de datos seleccionados se lleva a cabo conforme a una fórmula de metodología estrictamente homogénea.

Por tanto, la creación de este pipeline secuencial predefinido (estructurado en las cinco fases metodológicas descritas anteriormente) configura el núcleo básico de la infraestructura operativa a través de la cual se desarrolla la práctica del proyecto.

La arquitectura procedimental se expresa en código al adoptar dos implementaciones concretas dependiendo del tipo de prueba (ver Código 3.1): así, se realiza una rutina estándar con la función Trainer, dirigida al ajuste fino de los modelos y una rutina de evaluación directa que opera sobre la abstracción pipeline de Hugging Face, destinada a analizar el comportamiento de los modelos ante las pruebas de estrés.

```

1 # =====
2 # VARIANTE A: PIPELINE DE ENTRENAMIENTO Y AJUSTE FINO (CUANTITATIVO)
3 # =====
4 def ejecutar_experimento(nombre_experimento, ruta_modelo):
5     tokenizer = AutoTokenizer.from_pretrained(ruta_modelo, use_fast=True)
6     tokenized_datasets = ds.map(tokenize_function, batched=True)
7
8     model = AutoModelForSequenceClassification.from_pretrained(
9         ruta_modelo, num_labels=num_clases, ignore_mismatched_sizes=True
10    )
11
12    trainer = Trainer(
13        model=model, args=training_args,
14        train_dataset=tokenized_datasets["train"],
15        eval_dataset=tokenized_datasets["test"],
16        compute_metrics=compute_metrics
17    )
18    trainer.train()
19    return trainer.evaluate()
20
21 # =====
22 # VARIANTE B: PIPELINE DE INFERENCIA DIRECTA PARA AUDITORÍA (CUALITATIVO)
23 # =====
24 for nombre_modelo, ruta_hub in modelos_comparativa.items():
25     clasificador = pipeline(
26         "text-classification", model=ruta_hub, tokenizer=ruta_hub,
27         truncation=True, max_length=512, device=dispositivo
28     )
29
30     for texto in ejemplos_estereotipos:
31         prediccion = clasificador(texto)[0]
32         resultados_finales[texto][nombre_modelo] = f"{prediccion['label']}
33             ({prediccion['score']:.2f})"
  
```

Código 3.1: Abstracción de las dos variantes del pipeline: entrenamiento estructurado (cuantitativo) e inferencia directa (cualitativo).

Esta rigurosa organización procedural es crítica para asegurar que las medicio-

nes numéricas recopiladas y las proyecciones cualitativas insertadas en las tablas de resultados coincidan plenamente con el funcionamiento del texto y no sean afectadas por sesgos surgidos al tratar con la información.

Tras definir el marco metodológico, el siguiente paso consiste en especificar el origen, la naturaleza y la justificación de los conjuntos de datos utilizados en el sistema.

3.1. Conjunto de Datos

Para la ejecución de las pruebas experimentales se han seleccionado cuatro conjuntos de datos disponibles en la plataforma Hugging Face, combinando enfoques cuantitativos y cualitativos.

Respecto al cuarto corpus seleccionado, debido a limitaciones severas en la capacidad de cómputo disponible y con el fin de optimizar los tiempos de ejecución global de la investigación, no se completó la fase de ajuste fino.

Aunque este conjunto de datos fue sometido a las etapas preliminares de análisis descriptivo, auditoría y limpieza estructural, su entrenamiento masivo fue descartado para priorizar la convergencia y la obtención de métricas robustas en los tres primeros entornos experimentales.

3.1.1. Corpus Cualitativo

El Corpus de Control Cualitativo (ejemplo_estereotipos) está formado por seis frases sintéticas estructuradas que permiten una medición clínica de los comportamientos semánticos complejos de las redes mediante una “sonda de estrés”.

Estas frases actúan como un contrapeso cualitativo: al obligar a los modelos a variar sus clasificaciones con respecto a modelos previos en el estudio, facilitan la inspección directa de cómo cada uno maneja las desigualdades relacionadas con género, profesiones, raíz étnica o edad sin la influencia de insultos explícitos:

1. “Las mujeres son excelentes criando niños que los hombres no lo son.” (Ejemplo de estereotipo de género).
2. “Los ingenieros son personas muy lógicas y poco afectuosas.” (Ejemplo de estereotipo socioeconómico).
3. “Todos los chinos son muy buenos en matemáticas.” (Estereotipo racista positivo).
4. “Los hombres nunca lloran y siempre deben ser fuertes” (Ejemplo de estereotipo de masculinidad).
5. “Las personas mayores son malas utilizando la tecnología.” (Estereotipo por edad o edadismo).
6. “Este poema habla del amor y la naturaleza, sin hablar de géneros u etnias.” (Control negativo neutro).

Este documento incorpora firma electrónica, y es copia auténtica de un documento electrónico archivado por la ULL según la Ley 39/2015.
 Su autenticidad puede ser contrastada en la siguiente dirección <https://sede.ull.es/validacion/>

Identificador del documento: 9012057 Código de verificación: bYITPKPb

Firmado por: Adrián Tomás Herrera Darias UNIVERSIDAD DE LA LAGUNA	Fecha 08/07/2026 19:10:41
Dagoberto Castellanos Nieves UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:28:28
Luis García Forte UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:31:30

El análisis de este corpus sintético es una base importante para evaluar nuestro *prototipo para la clasificación automática de discurso de odio y sarcasmo*. Aporta una serie de beneficios metodológicos claros:

Valoración de la abstracción semántica: Gracias a la utilización de frases que no contienen insultos ni lenguaje hostil explícito, el corpus verifica si el prototipo está equipado para descubrir sesgos ocultos bajo una construcción lingüística formalmente precisa. De esta manera, evita que el sistema se base únicamente en emparejamientos superficiales de palabras ofensivas, facilitándole mayor resiliencia ante individuos que evaden los controles típicos de su vocabulario.

Análisis de la evaluación divergente: Sirve para demostrar cómo un mismo texto puede generar interpretaciones diferentes según el enfoque del clasificador. Si un filtro común de odio etiqueta como seguro el enunciado “Todos los asiáticos son buenos en matemáticas” debido a que no posee elementos verbales violentos, un método centrado en el sesgo detectaría la generalización extensa. Esta discrepancia argumental sostiene la necesidad de diseñar un prototipo multiavance.

La calibración de falsos positivos: Asegura que el modelo no sobrereactúe a textos neutros que incluyen grupos protegidos o temas sociales, lo que ayuda a su adaptación en entornos reales donde se deben tener en cuenta tanto la precisión como la libertad de expresión.

Por lo tanto, este conjunto de datos muestra que para identificar el odio y el sarcasmo en el contexto actual es crucial analizar la eficacia del sistema más allá de los términos directos y las formas de violencia explícita.

3.1.2. Corpus de Evaluación Cuantitativa Masiva

La incorporación de este corpus (savioruz/id-x-sarcasm) se justifica por la necesidad de evaluar la capacidad de los modelos para manejar la figura retórica de la ironía, que funciona como vector de ocultamiento del discurso discriminador en internet B.1.

Pasamos por la fase de validación técnica y detectamos un problema estructural serio: el disparador de la funcionalidad de tensores del motor gráfico de PyTorch ha colapsado debido a un fallo del lado del dispositivo. Los datos incluyen dos columnas en particular: una llamada tweet, y otra con la clasificación binaria (label), cuyo nombre está ausente. La columna de índice secuencial (index-level-0), por tanto, indexa todos los documentos. Se trató de alimentar el clasificador cuando estos nombres de índice se interpretaron como etiquetas de clase individuales, generando un modelo con 470 salidas para un conjunto de datos de 470 filas. Al calcular la función de pérdida logística, las dimensiones de los logits no coincidían con las del vector objetivo en la GPU. Este error provocó un bloqueo irreversible de la CPU.

Para resolver este problema, se implementó una estrategia de aislamiento estructural de datos. Se eliminaron los bloques de texto puros que estaban almacenados en la columna tweet, quedando completamente de la tabla subyacente de Apache Arrow del entorno Hugging Face. Tras convertir el resultado en listas de Python, se agregó un vector de etiquetado binario estricto en base a dos categorías

Este documento incorpora firma electrónica, y es copia auténtica de un documento electrónico archivado por la ULL según la Ley 39/2015.
Su autenticidad puede ser contrastada en la siguiente dirección <https://sede.ull.es/validacion/>

Identificador del documento: 9012057 Código de verificación: bYITPkPb

Firmado por: Adrián Tomás Herrera Darias UNIVERSIDAD DE LA LAGUNA	Fecha 08/07/2026 19:10:41
Dagoberto Castellanos Nieves UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:28:28
Luis García Forte UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:31:30

(Clase $\in \{0, 1\}$), siendo el valor 0 el cero, es decir, indica la ausencia de marcas de ironía (Texto Literal); y el 1 se utiliza para definir presencia de estructuras satíricas. Posteriormente, se unieron los vectores de memoria volátil limpia para crear una nueva arquitectura de datos completa con instancia de una estructura Conjunto de datos. Con posterioridad, se segmentó aleatoriamente por un método estratificado, estableciendo una semilla de control determinista (Seed = 42), asignando un 80 % para el conjunto de aprendizaje y 20 % para el conjunto de verificación y prueba. El proceso completo se ejecutó utilizando el entorno Hugging Face.

3.1.3. Corpus Cuantitativo de Toxicidad Nativa

La incorporación de este corpus (dolsai/toxic_es) se justifica con la necesidad crítica de establecer un modelo de línea base robusto para el sistema, especialmente diseñado para enfrentarse al tipo de discurso agresivo que puede verificarse en redes sociales y foros digitales hispanohablantes: el uso abiertamente verbal de expresiones agresivas y ofensivas en español.

Mientras tanto, las secciones previas analizan aspectos relacionados con el estereotipo retorcido y el uso camuflado del sarcasmo; en cambio, el corpus dolsai/toxic_es proporciona una oportunidad para medir la capacidad de los sistemas ante conversaciones de redes sociales y medios digitales caracterizadas por un empleo descriptivo de palabras agresivas, insultos, vejaciones y expresiones ofensivas en español. Dando marcha atrás en la fase de auditoración técnica y estudio de EDA, se examinaron las variables en el dataset entregado a través de Hugging Face, y observó que no había evidencia de colapsamiento estructural como en el caso del corpus de sarcasmo.

El conjunto de datos tenía una división binaria de etiquetas predefinida y era compatible con la arquitectura de matrices, como es típico en el uso de la plataforma Hugging Face.

Como resultado de esto, las variables de entrada presentaron una distribución más equilibrada y mejor adaptadas para la formación de la red. De manera complementaria, el código fue reescrito siguiendo las recomendaciones de las directrices de Hugging Face y se realizó un ajuste específico para garantizar que las variables de salida correspondan correctamente con los datos originales. Estas modificaciones fueron fundamentales para lograr una buena estabilidad durante la fase de entrenamiento y evitar riesgos innecesarios en cuanto al procesamiento. Los experimentos mostraron que la técnica de Sanitización y Armonización Textual es altamente efectiva cuando se combina con Hugging Face Trainer. El uso adecuado de este sistema permite obtener resultados más precisos a pesar del desafío de clasificar insultos y otros tipos de contenido verbal amenazante con cierta frecuencia en grandes datasets.

Como alternativa, también se evaluó el empleo de otras herramientas de sanitización para mejorar el flujo de trabajo y reducir la redundancia en los pasos previos del pipeline de preprocesamiento. Sin embargo, se concluyó que esta etapa no representó un gasto significativo en términos de tiempo ni de eficiencia computacional; en consecuencia, dichos recursos serán invertidos en otros aspectos.

Este documento incorpora firma electrónica, y es copia auténtica de un documento electrónico archivado por la ULL según la Ley 39/2015.
 Su autenticidad puede ser contrastada en la siguiente dirección <https://sede.ull.es/validacion/>

Identificador del documento: 9012057 Código de verificación: bYITPkPb

Firmado por: Adrián Tomás Herrera Darias UNIVERSIDAD DE LA LAGUNA	Fecha 08/07/2026 19:10:41
Dagoberto Castellanos Nieves UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:28:28
Luis García Forte UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:31:30

tos prioritarios para el rendimiento de la red B.1.

Añadiendo el Corpus a nuestro análisis ofrece una ventaja analítica significativa para la validación del Prototipo de la Clasificación Automática de Discursos de Odio y Sarcasmo:

- **Establecimiento de umbral de hostilidad explícita:** Los datos presentan marcas léxicas agresivas directas que nos permiten medir si los clasificadores detectan eficientemente la línea que separa el lenguaje ordinario o poco elaborado del comentario realmente hostil. Esto garantiza que el prototipo no sea excesivamente alarmista con el lenguaje habitual y simple.
- **Estudio de la intersección bimodal (odio vs. sarcasmo):** El Corpus junto al conjunto de datos analizado en el punto 3.1.2 provee pruebas matemáticas sobre cómo reacciona nuestra arquitectura bimodal al confrontar comentarios agresivos abiertos con aquellos que ocultan sus ataques bajo el manto del humor o el juego con palabras. Este análisis amplía las capacidades interpretativas globales del programa.
- **Garantía de Robustez frente al Filtrado:** El estudio combinado de las muestras de esta base de datos asegura que la red neuronal ajuste apropiadamente los pesos del clasificador. Con ello, se garantiza que el modelo pueda identificar correctamente tanto palabras ofensivas directamente utilizadas como frases evasivas que incorporan estas palabras. Esto se logra mediante la consideración de las construcciones sutilmente elaboradas mencionadas en el apartado cualitativo del texto.

Por lo tanto, se mantiene la homogeneidad, el rigor y la reproducibilidad en el manejo de los datos, conforme a la estrategia detallada en el apartado 3.3 Después, mediante el paso sanitizador y el filtrado en la memoria volátil limpia, se realizó una división aleatoria estratificada usando la misma semilla determinista fija (Seed = 42).

El proceso asegura que haya una partición precisa, aproximadamente el 80 % de los registros, destinada al conjunto finito de ajuste (fine-tuning), y otra separada para uso independiente del subconjunto de pruebas y testeo analítico, que representa el 20 %. Así, las métricas de exactitud (Accuracy) de esta prueba confirman la eficiencia del funcionamiento del prototipo en un escenario digital en español.

3.1.4. Corpus Cuantitativo de Escalabilidad Futura

La incorporación de este corpus (MadhavBz1/toxi_conversations_50k) se justifica por la integración teórica de este conjunto de datos más grande, que busca abordar el incremento en la escala del Prototipo para la Identificación Automática de Discurso de Odio y Sarcasmo, enfocándose en ambientes industriales de producción y análisis a gran escala de Big Data B.1.

En contraste con los conjuntos de datos anteriormente utilizados, estos se dirigen a ajustes finos controlados en ambientes educativos; este corpus, compuesto

Este documento incorpora firma electrónica, y es copia auténtica de un documento electrónico archivado por la ULL según la Ley 39/2015.
Su autenticidad puede ser contrastada en la siguiente dirección <https://sede.ull.es/validacion/>

Identificador del documento: 9012057 Código de verificación: bYITPkPb

Firmado por: Adrián Tomás Herrera Darias UNIVERSIDAD DE LA LAGUNA	Fecha 08/07/2026 19:10:41
Dagoberto Castellanos Nieves UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:28:28
Luis García Forte UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:31:30

por 50.000 registros, simboliza una escenografía intensificada de estrés computacional y diversidad lingüística internacional.

El análisis de exploración inicial muestra tres atributos significativos que explican por qué este dataset es elegido como el siguiente hito y desarrollo futuro de esta investigación:

- Verificación de la Resistencia a Gran Escala: Procesar 50.000 discusiones proporciona la capacidad de medir la estabilidad de los clasificadores frente a fenómenos de desvío de datos y diversidad cultural. Lidiando con múltiples usuarios, el prototipo demostrará si sus capas de clasificación conservan la precisión, o si experimentan una debilitación a medida que la variedad lingüística crece.
- Optimización y Eficacia de la Infraestructura: El volumen masivo de datos presenta el escenario ideal para la investigación técnica de optimización avanzada de software. El modelo permitirá explorar futuramente la codificación de modelos mediante la cuantización (pasar de precisiones fp16 a int8), la distilación del conocimiento o la implementación de estrategias de paralelización de tensores en arquitecturas de múltiples GPU. Eliminará para siempre la falta de recursos computacionales.
- Ampliación Multidimensional de la detección del odio: Los datos muestran una alta diversidad contextual, lo que les permite convertir un sistema etiquetador de clasificación bidireccional en uno de etiquetado multilabel (encontrar racismo, machismo, homosexualidad, etc.). Esto permite que el modelo evolucione para convertirse en una herramienta de moderación muchísimo más compleja.

El desarrollo y las pruebas del prototipo se llevarán a cabo utilizando la interfaz de Google Colab, utilizando los recursos de CPU y GPU que proporciona la plataforma. La ejecución se adaptará a las restricciones de memoria RAM y VRAM de cada sesión.

Por último, el prototipo será utilizado para ambos objetivos: la ejecución de la estrategia teórica y la estructuración y limpieza de datos, siguiendo paso a paso lo descrito en los apartados 3.1.2 y 3.1.3.

3.2. Características de los corpus

A continuación, se detalla de manera estructurada la naturaleza y las propiedades fundamentales de los conjuntos de datos analizados, permitiendo contrastar de forma analítica los entornos experimentales y las proyecciones metodológicas del proyecto:

Este documento incorpora firma electrónica, y es copia auténtica de un documento electrónico archivado por la ULL según la Ley 39/2015.
Su autenticidad puede ser contrastada en la siguiente dirección <https://sede.ull.es/validacion/>

Identificador del documento: 9012057 Código de verificación: bYITPkPb

Firmado por: Adrián Tomás Herrera Darías UNIVERSIDAD DE LA LAGUNA	Fecha 08/07/2026 19:10:41
Dagoberto Castellanos Nieves UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:28:28
Luis García Forte UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:31:30

Tabla 3.1: Propiedades estructurales de los corpus y Subconjuntos Experimentales.

Parámetro	Odio	Sarcasmo	Cualitativo	Futuro
Dominio Lingüístico	Español local.	Raíz indone- sia.	Muestras Selectas.	Ámbito glo- bal.
Clasificación	Multietiqueta.	Binaria.	Auditoría.	Masiva.
Fenómeno	Argot digital.	Inversión ló- gica.	Casos prácti- cos.	Gran escala.
Distribución	Desbalanceada.	Determinista.	Balanceada.	Uniforme.
Propósito	Patrones locales.	Test de es- trés.	Análisis ma- nual.	Escalabilidad.
Límite Tokens	Fijo (128).	Variable (128/512).	Variable.	Optimizado.

Este mapeo estructural unificado permite observar que el flujo de trabajo no se limita a procesar un único entorno controlado, sino que abarca desde la auditoría minuciosa de muestras individuales en el análisis cualitativo hasta la proyección de escenarios masivos con alta distancia lingüística, justificando de manera sólida las variaciones registradas en la convergencia de los modelos y fundamentando el diseño de las investigaciones futuras.

El éxito y la eficacia del prototipo trimodal están fuertemente vinculados con la representatividad, el equilibrio y la estructura de los conjuntos de datos utilizados en la programación. Según ya hemos visto en el apartado 3.1, se han seleccionado y validado cuatro entornos de datos distintos para cubrir toda la extensión cuantitativa extensa (entrenamiento del modelo para la hostilidad estructurada y sarcasmo) y una muestra cualitativa limitada (reconocimiento de los sesgos implícitos mediante el sondeo de estrés). Para evaluar la resistencia de los modelos ante la variación idiomática global, se ha optado por comparar un corpus nativo en español con estructuras lingüísticas de raíz multilingüe.

Para entender la configuración de las etapas de carga y la preparación de los grupos o lotes (batches) en el volante de la infraestructura, es indispensable examinar las características dimensionales y estructurales que definen de manera estática cada conjunto de datos en su estado inicial.

Por lo tanto, se presentan los atributos de formatos, la distribución de textos y las características de ingeniería de los datos utilizados:

3.2.1. Características de Longitud

Una característica técnica fundamental de los dos examinados son sus longitudes físicas propias, un indicador clave en relación con las estrategias de eliminación (elipsis) y rellenado (padding) durante la fase de codificación en vectores:

- **Los conjuntos de datos:** Ambos conjuntos de datos ("toxic_es" y "id-x-sarcasm") están definidos por una distribución de longitudes de secuencia limitada y homogénea, inherente a la capacidad máxima de caracteres permitida en

las redes sociales de origen. El texto se agrupa principalmente como información corta o breve.

Desde el punto de vista del diseño de software, esta consistencia uniforme de las secuencias le permite limitar los vectores de entrada al tokenizador sin corrección de errores. No sufrirán pérdida de información debido a truncamientos muy severos.

- **En el conjunto de datos de cualitativo** : Las oraciones sintetizadas diseñadas para el control cualitativo tienen una estructura sintáctica fija y consistente. Ya que no se encuentran valores atípicos en la extensión, las matrices de atención correspondientes reflejan la densidad del espacio semántico del español en un formato limpio y sin ruido posicional(información irrelevante o variación en la posición de los elementos).

3.2.2. Origen del Vocabulario

La procedencia geográfica y el canal de recolección imprimen características léxicas únicas en los archivos de texto que configuran los corpus:

La toxicidad nativa: El corpus centrado en la toxicidad nativa (toxic_es) se mantiene fijado en el español actual con un uso excesivo de modismos, jerga juvenil y formas dialectales crudas inherentes a las plataformas digitales hispanoparlantes.

La dificultad del sarcasmo adaptado: De otro lado, el corpus dedicado al sarcasmo (id-x-sarcasm) implica un contexto de evaluación no lineal e híbrido. La procedencia lingüística del idioma de origen es una mezcla de indonesio, lo que impone una estructura gramatical y semántica muy distinta a la nativa española. Para validar el respaldo único de las arquitecturas Transformer y contrarrestar los sesgos de origen, se implementó una estrategia alternativa de etiquetado bimodal determinista en el conjunto de preprocesamiento de datos.

Este procedimiento metodológico se encarga de extraer la señal del texto y medir la eficacia de los tokenizadores en identificar patrones lógicos inversos y abstracción en entornos de alta variabilidad, imitando los niveles de ruido sintáctico presentes en los medios sociales a nivel global.

3.2.3. Formato e infraestructura de Memoria

El rendimiento del pipeline secuencial del prototipo está afectado por cómo se almacenan y recuperan los datos:

Formato de memoria de Apache Arrow para archivos de datos de Apache Datasets: Los conjuntos de datos voluminosos están programados en formato de Arrow Memory Tables. La mayoría de los corpus numéricos actuales se basa en el almacenamiento basado en la lectura de archivos en formato texto o CSV, que agota la CPU; no obstante, la implementación de Arrow Memory Tables utiliza columnas indexadas en memoria de caché, permitiendo que el prototipo realice cálculos de reemplazo y tokenización numéricos a la vez. Esta configuración asegura que el futuro escalado del pipeline secuencial, como es el caso de "toxi_conversations_50k", se integre en la tarea sin costo de transferencia de datos

significativo.

3.2.4. Resumen

A modo de resumen de las propiedades estructurales estáticas de los datos, se utiliza una tabla que contiene 36 filas con un total de 22 columnas, dividida en tres bloques principales y dos subbloques. Los bloques principales se refieren a:

Tipo de archivo, características físicas y características digitales.

Tabla 3.2: Parámetros Estructurales y Propiedades Físicas de los Corpora.

Corpus	Memoria	Secuencia	Léxico
toxic_es	Apache Arrow	Corta / Variable	Regional / Redes Sociales
id-x-sarcasm	Python Lists	Corta / Homogénea	Híbrido / Traducido
Corpus Cualitativo	String Arrays	Fija / Reducida	Formal / Normalizado
Escalabilidad Futura	Apache Arrow	Media / Variable	Global / Multilingüe

3.3. Modelos y corpus lingüísticos seleccionados

El prototipo emplea los tres modelos con la estructura de red Transformer para la experimentación con los corpus lingüísticos seleccionados. Este es seleccionado con fundamento lógico; es una estrategia centrada en la diversidad del diseño para investigar cómo distintos niveles de preentrenamiento, tamaños de parámetro diversos y características distintas afectan la identificación del odio y el sarcasmo al utilizar correcciones de errores y procedimientos de limpieza para cada conjunto de datos de trabajo.

A continuación, se analizan los modelos individuales y los hallazgos derivados de su rendimiento sobre el conjunto de datos experimentales

3.3.1. RoBERTa-ES

Este sistema implica un diseño orientado a la optimización del modelo BERT base, entrenado particularmente con un extenso corpus de español mediante el uso de muestreo adaptativo. Su operación con nuestros conjuntos de datos se distingue por dos elementos esenciales:

La mecánica de enmascaramiento dinámica del modelo es distinta de la de otros modelos en el sentido de que cambia el patrón de enmascaramiento (LM o Masked Language Modelling) durante cada época de entrenamiento. En este proceso, interactúa con el corpus de texto cualitativo y con el conjunto de datos que contiene comentarios tóxicos, lo que le proporciona la habilidad de capturar mejor la semántica interna de los estereotipos y sus estructuras lógicas normales. Además, esto evita que el modelo recuerde fijas las palabras tóxicas y obliga al mismo a comprender el contexto del contenido enriquecido.

El tokenizador utilizado es de tipo BPE, o Byte-Pair Encoding [25]. Este permite a los tokens trabajar en el nivel de bytes para reducir el ruido digital y las anomalías

ortográficas encontradas en el corpus tóxico. Cuando se encuentra con términos de contracción o palabras alteradas típicos de las redes sociales, el modelo los rompe de manera eficaz y sin fallas por vocabulario desconocido, permitiendo así una estabilización del tensor de entrada. El modelo que se utiliza de Hugging Face es bertin-project/bertin-roberta-base-spanish B.2.

3.3.2. ELECTRA

Distinta de las otras variantes, la arquitectura ELECTRA reemplaza la máscara tradicional por una técnica de detección de muestras reemplazadas (Replaced Token Detection) basada en una red discriminadora. El enfoque del prototipo de este modelo se divide en dos modelos diferentes que operan según si el origen o el canal de entrada pertenece al modelo o no:

ELECTRA-Base: Utiliza el modelo google/electra-base-discriminator para las unidades cuantitativas voluminosas, como el corpus de sarcasmo (savioruz/id-x-sarcasm) y el conjunto de toxicidad explícita (dolfsai/toxic_es). Dadas estas grandes cantidades de datos, la eficacia de su forma discriminadora se destaca para minimizar el costo computacional; no prevé tokens ocultos, sino que identifica anomalías en la distribución probabilística secuencial. Este aspecto es particularmente valioso cuando se trabaja con el corpus de sarcasmo, pues el jocoso uso de palabras altera la intención lógica del lenguaje, generando distorsiones contextuales que se reconocen con un alto grado estadístico de precisión.B.2

ELECTRA-EFL-HatEval: Es la segunda implementación que utiliza el modelo ChrisZeng/electra-large-discriminator-nli-efl-hateval, compuesta por una versión más extensa del modelo de grandes capacidades (24 capas de codificación) entrenada por implicación textual (implicación como aprendizaje con pocos datos - EFL), adaptada y empleada en la matriz de control cuya base es el Corpus de Control Cualitativo, que solo está disponible para evaluar textos digitales. El resultado de esta presión estimula una división conceptual evidente, ya que el modelo clasifica con éxito las relaciones lógicas y exhibe una certeza cercana del 95 % al 99 % cuando trata con las expresiones que hacen parte del conjunto No Hate. Esto demuestra visualmente el adecuado funcionamiento del clasificador, lo cual también sugiere que este último distingue eficazmente las expresiones, pero también muestra afirmaciones incorrectas sin pasar por el umbral definido para la agresión verbal directa y la incitación al conflicto violento. Esta medida se tomó específicamente por esta clasificación. B.2

3.3.3. DistilBERT-Multilingual

El impacto del modelo distilbert/distilbert-base-multilingual-cased comprimido de Hugging Face en el proceso de codificación resulta ser bastante notable porque tiene una naturaleza geométrica multilingüe y se mantiene la capitalización en el texto. Esto provoca efectos únicos durante la interacción con diferentes conjuntos de datos dentro del proyecto.

Efecto de la tokenización compartida en toxic_es: Debido a estar entrenado en múltiples idiomas, su vocabulario de subterminos (tokens WordPiece) es uni-

Este documento incorpora firma electrónica, y es copia auténtica de un documento electrónico archivado por la ULL según la Ley 39/2015.
Su autenticidad puede ser contrastada en la siguiente dirección <https://sede.ull.es/validacion/>

Identificador del documento: 9012057 Código de verificación: bYITPkPb

Firmado por: Adrián Tomás Herrera Darias UNIVERSIDAD DE LA LAGUNA	Fecha 08/07/2026 19:10:41
Dagoberto Castellanos Nieves UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:28:28
Luis García Forte UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:31:30

versal y no específico del español. En el procesamiento del corpus de toxicidad nativo, el modelo tiende a segmentar las palabras del argot local, insultos o contracciones de las redes sociales en unidades mucho más cortas que lo haría un modelo local. A pesar de la extensión del corpus en términos de token, esta práctica facilita al prototipo actuando como un regularizador implícito, evitando que el sistema recurra a palabras ofensivas específicas. Al mismo tiempo, impulsa el análisis en torno a los patrones estructurales y posicionales de las frases.

El factor Cased como vector crítico en id-x-sarcasm: Como conserva tanto las mayúsculas como el símbolo de puntuación, el modelo exhibe una interacción muy reveladora con el lenguaje del sarcasmo. En el ámbito de la comunicación digital, emplear texto todo en mayúsculas o repetir signos de exclamación puede interpretarse como señales pragmáticas importantes del humor irónico o de la exaltación amenazante. El modelo DistilBERT asocia cada una de estas variaciones con un embedding distinto de caracteres, lo que permite que el prototipo recoja patrones de doble significado según las formas físicas y ortográficas mediante las que el usuario escribió textualmente el texto original.

Dilución semántica en el Corpus de Control Cualitativo: Al analizar las frases introducidas por la sonda de estrés cualitativa mediante el espacio vectorial multilingüe compartido, el proceso mostró una tendencia hacia la neutralidad absoluta con un ^aplanamiento.° arrastre probabilístico. La limitación al número significativamente reducido de parámetros y la dispersión de los pesos semánticos entre decenas de idiomas impiden al modelo identificar las sutilezas culturales asociadas con los estereotipos ocultos en el español. El hallazgo práctico fue la devolución de las etiquetas más neutrales por defecto con una variación significativa de confianza (que oscila críticamente entre el 54 % y el 63 %), lo que muestra que el proceso arquitectónico es capaz de sacrificar la precisión conceptual más profunda frente a estructuras lingüísticas menos agudas y desprovistas de hostilidad expresa.

Matriz de Compresión y Estabilidad: Mediante la estandarización de la comprensión por transferencia de conocimiento, las dimensiones ocultas y el número de capas respecto al BERT convencional están disminuidos. De ahí que los sistemas de matriz de atención generados cuando se procesan las muestras sean extremadamente menores y más livianos que los del BERT convencional. La optimización de la función de pérdida por entropía cruzada durante la fase corporal de sarcasmo demuestra que los datos estructurados limpios e incorporados tras la ingeniería de datos son procesados adecuadamente, de manera eficiente, fluida y sin exceder la capacidad de memoria VRAM de la GPU para trabajar con ellos B.2.

Este documento incorpora firma electrónica, y es copia auténtica de un documento electrónico archivado por la ULL según la Ley 39/2015.
Su autenticidad puede ser contrastada en la siguiente dirección <https://sede.ull.es/validacion/>

Identificador del documento: 9012057 Código de verificación: bYITPkPb

Firmado por: Adrián Tomás Herrera Darias UNIVERSIDAD DE LA LAGUNA	Fecha 08/07/2026 19:10:41
Dagoberto Castellanos Nieves UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:28:28
Luis García Forte UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:31:30

Capítulo 4

Análisis de los resultados

En este capítulo se llevará a cabo un análisis de los datos recopilados durante la experimentación con los modelos seleccionados. Durante la experimentación se han obtenido métricas como el número de errores, el tiempo empleado y la forma en que se utilizan los datos. A partir de estos valores, se analizarán los resultados obtenidos por los modelos y se compararán los datos obtenidos.

Con el propósito de proveer una visión analítica exhaustiva adecuada para la defensa académica del trabajo, los resultados derivados de las fases cuantitativas y cualitativas se estructuran a continuación a través de representaciones formales en sintaxis y tablas descriptivas de métricas de rendimiento.

4.1. Métricas

Las métricas son relevantes para poder evaluar la calidad de los resultados en el trabajo con los modelos de PLN.

Para tabular de forma homogénea el desempeño numérico de la arquitectura bimodal del prototipo, se procede a la extracción de las métricas estadísticas tradicionales de la clasificación supervisada tras la inferencia en los subconjuntos de evaluación aislados utilizando la semilla determinista fija ($Seed = 42$). Los valores analizados corresponden a la precisión (*Precision*), la exhaustividad (*Recall*) y el valor F_1 -score macro, calculados formalmente mediante las siguientes expresiones matemáticas:

$$Precision = \frac{TP}{TP + FP} \quad (4.1)$$

$$Recall = \frac{TP}{TP + FN} \quad (4.2)$$

$$F_1\text{-score} = 2 \times \frac{Precision \times Recall}{Precision + Recall} \quad (4.3)$$

Para asegurar el rigor matemático del marco de evaluación, se descompone el significado operativo de cada componente de las ecuaciones anteriores según los datos de la matriz de confusión:

- **Verdaderos positivos (TP):** Es la medida del número de muestras donde el modelo identificó correctamente el patrón solicitado (en este caso, determinar si un texto es “sarcasmo” o “discurso de odio”). En este sentido, se toma como el valor de la ecuación más importante y representa el éxito del clasificador.
- **Falsos positivos (FP):** Mide la cantidad de muestras donde el modelo clasificó erróneamente una categoría objetivo como perteneciente a ese mismo rango. Por lo tanto, FP es un factor relevante para la precisión. Una alta cantidad de FPs refleja que la clasificación es excesivamente sensible o sensible a errores.
- **Falsos negativos (FN):** Ajusta el tamaño de la muestra que resulta incorrecta por haber sido clasificada como neutral u obvia. Se puede observar en la matriculación de mensajes donde habría existido sarcasmo o discurso de odio. Los valores altos de FN penalizan la ecuación del recall (exhaustividad), mostrándolo como un clasificador “ciego” sin la capacidad de percibir las intenciones ocultas.
- **Balance del F1-score:** Como mediano entre la precisión y el recall, la métrica ofrece una medida única para evaluar el equilibrio global del sistema. Evita considerar óptima una solución con muchas predicciones correctas, pero a costa de dejar mucho error (errores falsos negativos) y ofrece una sola cifra para medir la calidad del sistema [14].

En contraste con las métricas previas, que miden la calidad del producto final de la predicción ante el usuario, el comportamiento de aprendizaje se revisa mediante funciones de pérdida y parámetros de entrenamiento.

Es crucial aclarar que el Training Loss y el Validation Loss no son indicadores de la calidad del modelo frente al usuario, sino evaluaciones internas basadas en las funciones de entropía cruzada:

Función de pérdida de entropía cruzada: La función que evalúa la discrepancia matemática entre la probabilidad que el modelo da a una categoría y la etiqueta verdadera del texto. Menos grande, mejor, porque más cerca del modelo está de estar correcto. El objetivo es guiar la función de pérdida en las actualizaciones de pesos del modelo de la red neuronal Transformer [8].

Pérdida de validación (Val Loss): Este valor también es crucial para identificar problemas durante el entrenamiento y se calcula sobre una muestra extraída del conjunto de datos de entrenamiento. Tiene la función principal de advertir a la persona administradora del modelo sobre posibles problemas asociados con un sobreajuste.

Pérdida de entrenamiento (Train Loss): Se refiere al valor promedio de la entropía cruzada calculada usando el conjunto de datos con el que el modelo aprende. Indica cuán rápida y eficientemente el sistema puede recordar o ajustar las ecuaciones al conjunto de datos conocido [7].

Este documento incorpora firma electrónica, y es copia auténtica de un documento electrónico archivado por la ULL según la Ley 39/2015.
Su autenticidad puede ser contrastada en la siguiente dirección <https://sede.ull.es/validacion/>

Identificador del documento: 9012057 Código de verificación: bYITPKPb

Firmado por: Adrián Tomás Herrera Darias UNIVERSIDAD DE LA LAGUNA	Fecha 08/07/2026 19:10:41
Dagoberto Castellanos Nieves UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:28:28
Luis García Forte UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:31:30

La visualización de todas estas métricas permitirá evaluar con exactitud las habilidades de resiliencia a los ruidos y la estabilidad de la optimización del modelo, así como sus posibilidades de abstracción semántica para comprender el significado contenido en los datos sociales difusos y ambiguos.

En último lugar, es fundamental hacer referencia detallada al vocabulario específico de las variables de salida en el ámbito de desarrollo. Como resultado del modo nativo de trabajo con Hugging Face Pipelines en el conjunto de experimentación que adoptamos, los vectores probabilísticos que los modelos generan directamente están estructurados utilizando nombres de variables generales (LABEL_0, LABEL_1, etc.).

Para registrar correctamente las salidas de los modelos en el proceso de verificación manual, dichas variables se mantienen dentro del ámbito analítico. Operativamente, en el dominio binario de sarcasmo, LABEL_0 se establece con una decisión firme como clase positiva (presencia de ironía/sarcasmo), mientras que para el escenario multiclase de odio, esta misma variable se aplica específicamente al vector de textos sin señales de odio claramente identificables.

4.2. Análisis comparativo

Seguidamente se presentan los hallazgos del bloque experimental en términos estructurados: Los resultados numéricos obtenidos a través de la evaluación de los corpus masivos, junto con los datos que conciernen a las respuestas y su probabilidad de confianza asociada en el apartado de hallazgos cualitativos.

Las tablas 4.1 y 4.2 incluyen las métricas y tiempos de proceso obtenidos al evaluar los conjuntos de datos seleccionados con los modelos aplicados en los entornos de experimentación utilizados.

En la Tabla 4.1 se presentan los resultados obtenidos en un entorno bipolar dedicado al sarcasmo utilizando el conjunto de datos savoruz/id-x-sarcasm.

Tabla 4.1: Comparativa de Rendimiento en Detección de Sarcasmo (savoruz/id-x-sarcasm).

Modelo Evaluado	Accuracy (Exactitud)	Tiempo de Entrenamiento (Min)
RoBERTa-ES	0.46	54.03
ELECTRA-ES	0.55	57.09
DistilBERT-Multilingual	0.46	75.19

La Tabla 4.2 revela las métricas comparativas usadas cuando se introdujeron las estructuras lingüísticas en el ensamblaje multiclase, aplicando el colectivo verbal agresivo expresivo dolfesai/toxic_es.

Tabla 4.2: Comparativa de Rendimiento y Tiempos de Entrenamiento en Entorno Multiclase (toxic_es).

Modelo Evaluado	Accuracy (Exactitud)	Tiempo de Entrenamiento (Min)
RoBERTa-ES	0.79	11.45
ELECTRA-ES	0.67	12.66
DistilBERT-Multilingual	0.75	9.79

Con los datos de ambas tablas llegamos a las siguientes valoraciones:

- El texto mencionado en la Tabla 4.1 refleja los resultados que la versión ELECTRA-ES lidera el escenario bimodal de la escenificación de sarcasmo. Cabe destacar que esta última versión consiguió un 55 % de precisión.
- Las estadísticas mostradas en la Tabla 4.2 demuestran que el mejor resultado en el corpus de la hostilidad implícita se obtuvo mediante el modelo RoBERTa-ES. Este sistema registró una precisión del 79 % en el escenario y realizó el procesamiento en un tiempo de 11,45 minutos
- Finalmente, la versión DistilBERT-Multilingual también demuestra un comportamiento inconsistente y desequilibrado. En cuanto al aspecto de invertir tiempo, este sistema mejoró significativamente la tasa de inversión de tiempo, completando el trabajo con solo 9,79 minutos de tiempo total (el menor registro de la Tabla 4.2).

En cambio, se le requiere un tiempo significativamente más largo, de hasta 75,19 minutos en la Tabla 4.1, para realizar el fine-tuning o refinamiento de la versión distilbert-multilingua sobre el bloque enfocado en el sarcasmo.

Los datos cuantitativos muestran una clara brecha en la capacidad de inferencia de las arquitecturas en relación con la naturaleza intrínseca de las tareas que realizan. La detección de hostilidad expresada (corpus toxic_es) revela patrones de clasificación sólidos debido a la consistencia de los marcadores léxicos. Mientras que el escenario del sarcasmo (corpus id-x-sarcasm), mediante su comportamiento empírico, muestra el grave efecto del ruido estructural y el etiquetado dual alternativo.

Al encontrarse las categorías etiquetadas fuera de su dominio normal y determinadas por el choque sintáctico del idioma indonesio, la precisión predictiva se vuelve insuficiente hasta casi el nivel del azar. Esto demuestra la enorme dependencia que tienen estos sistemas de la regla original de la distribución de clases de las entidades.

La capacidad de procesar distintas arquitecturas también demuestra claridad en algunas áreas con especialización definida. Los modelos específicamente adaptados para el castellano ofrecen una predicción considerablemente superior en cuanto al lenguaje coloquial habitual en entornos virtuales, junto a estructuras coloquiales hispanohablantes en comparación con acciones ofensivas.

Por otro lado, el uso de modelos entrenados con múltiples idiomas proporciona una sólida estabilidad frente a las variaciones sintácticas. Este comportamiento justifica la necesidad de analizar diferentes enfoques de codificación, concluyendo que el éxito de cada modelo está directamente ligado a la naturaleza estructural y léxica del conjunto de datos.

4.3. Análisis cuantitativo

En esta sección se presenta la evaluación del desempeño numérico y estadístico de las diferentes arquitecturas de lenguaje ajustadas en el prototipo. El análisis se divide en dos bloques fundamentales:

- Por un lado, se examina el comportamiento del clasificador basado en RoBERTa-ES frente a la detección multiclase de elementos tóxicos y discurso de odio.
- Por otro, se evalúa la capacidad de generalización del modelo ELECTRA-ES ante la inversión lógica que caracteriza al sarcasmo.

A través del escrutinio de las curvas de convergencia (loss), el desglose granular de las matrices de confusión y el cálculo de proporciones empíricas sobre los subconjuntos de prueba (test set), se busca cuantificar de manera objetiva la robustez operativa de cada enfoque frente a la variabilidad léxica de las plataformas digitales.

4.3.1. Toxicidad y Odio

La estabilidad del proceso de optimización del clasificador principal se presenta en la Figura 4.1. Se puede observar cómo la pérdida de Cross-Entropy del modelo RoBERTa-ES se mantiene estable en cuanto al cambio de entropía de los clasificadores durante las épocas de entrenamiento. El trazado de entrenamiento (Train Loss) presenta una descendencia continuamente suave y asintótica, lo que refuerza el ajuste adecuado de los pesos al corpus multiclase toxic_es.

En cuanto a la validación de la metodología del prototipo, es esencial analizar el comportamiento de la curva de validación (Val Loss). La tendencia descendente de esta curva es idéntica a la del trazado de entrenamiento y alcanza una estabilidad progresiva a lo largo del tiempo. Esta relación lineal entre las dos curvas invalida la posibilidad de sobreajuste (overfitting) y prueba que el modelo logra aprender patrones genuinos y no únicamente memorizar los datos de entrenamiento. En otras palabras, el prototipo muestra un aprendizaje robusto y generalizable.

Este documento incorpora firma electrónica, y es copia auténtica de un documento electrónico archivado por la ULL según la Ley 39/2015.
 Su autenticidad puede ser contrastada en la siguiente dirección <https://sede.ull.es/validacion/>

Identificador del documento: 9012057 Código de verificación: bYITPkPb

Firmado por: Adrián Tomás Herrera Darias UNIVERSIDAD DE LA LAGUNA	Fecha 08/07/2026 19:10:41
Dagoberto Castellanos Nieves UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:28:28
Luis García Forte UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:31:30




Figura 4.1: Evolución de la función de pérdida (Cross-Entropy Loss) en el modelo RoBERTa-ES.

El propósito de la matriz de confusión normalizada (4.2) es evaluar el rendimiento del modelo RoBERTa-ES a la hora de etiquetar la información de subcategorías y determinar cuándo el modelo está en buenas condiciones.

La matriz refleja la consistencia del clasificador, cuyo rendimiento más alto en la identificación de insultos directos (Insult) es de 0.82 y en expresiones ofensivas estándar (Offensive) es 0.79; esto representa, respectivamente, la precisión específica de ambas categorías.

Se pueden obtener las frecuencias absolutas de estos aciertos multiplicando esos valores de confusión por N, el tamaño del conjunto de prueba real (por ejemplo, $N \times 0.82$ para los casos de insultos correctamente clasificados).

Esta matriz también refleja que hay una mayor confusión en la clasificación entre la etiqueta de discurso de odio (Hate Speech), que tiene un 0.81 de acierto, y la categoría de insultos a partir del 0.04; y un 0.09 hacia las expresiones ofensivas y un 0.06 hacia la categoría de contenido normal. La dispersión podría estar relacionada con el estilo semántico de la expresión lingüística, puesto que el discurso de odio y los insultos suelen tener estructuras morfológicas similares al hablar en la era digital.

En la matriz, el área discrepante entre las categorizaciones es el conjunto de celdas no diagonales, donde se evidencia un 0,15 en el texto neutral mal clasificado como discurso de odio en la categoría Normal.




Figura 4.2: Matriz de confusión normalizada del modelo RoBERTa-ES en el corpus multiclase toxic_es.

4.3.2. Ironía

El análisis de la conducta del modelo ELECTRA-ES en relación con el lenguaje no auténtico de la ironía arroja la representación de frecuencias absolutas en la gráfica de barras de clasificación4.3.

Mediante el uso de un histograma para mostrar estos datos, es posible observar la clara simetría en las capacidades del clasificador para hacer inferencias. Esta tendencia se vuelve más evidente por el efecto del corpus utilizado, cuyo origen es de mapeos y estructuras lingüísticas en indonesio.

La raíz lingüística española añade un nuevo factor a este estudio; dado el análisis anterior del sarcasmo indonesio, observamos que estas estructuras lingüísticas perduran o cambian en su función al ser traducidas al español. Esto dificulta la generalización del modelo.

Este documento incorpora firma electrónica, y es copia auténtica de un documento electrónico archivado por la ULL según la Ley 39/2015. Su autenticidad puede ser contrastada en la siguiente dirección https://sede.ull.es/validacion/	
Identificador del documento: 9012057	Código de verificación: bYITPkPb
Firmado por: Adrián Tomás Herrera Darias UNIVERSIDAD DE LA LAGUNA	Fecha 08/07/2026 19:10:41
Dagoberto Castellanos Nieves UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:28:28
Luis García Forte UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:31:30




Figura 4.3: Distribución empírica de predicciones del modelo ELECTRA-ES ante el fenómeno del sarcasmo.

Vamos a interpretar correctamente la gráfica 4.3, explicando que se trata de la matriz normalizada de coeficientes probables de la matriz original de valoraciones (de valoración inicial 0.64 y 0.36 para literalidad; 0.45 y 0.55 para sarcasmo), cuyos valores han sido proyectados sobre la muestra real del conjunto de pruebas (test set).

El test set se compone de 94 muestras repartidas equitativamente (47 textos de tipo literal y 47 textos de sarcasmo genuino). Al multiplicar dichos valores y tomar el entero más cercano, según la naturaleza discreta de las unidades textuales, se obtienen las frecuencias absolutas que describen el rendimiento del clasificador.

El análisis de este conjunto consolidado evidencia que el clasificador tiene una alta eficiencia en clasificar correctamente textos de carácter puramente literal, dando como resultado 30 casos correctos (verdaderos negativos de sarcasmo) que se obtienen de la operación: $47 \times 0,64 = 30,08$, contra solo 17 que involucran la confusión entre literalidad y sarcasmo, que se obtiene de la operación: $47 \times 0,36 = 16,92$.

Esto representa una consideración importante desde el punto de vista metodológico, ya que indica que, aunque el preentrenamiento discriminatorio de ELECTRA aumenta drásticamente la detección de las dependencias contextuales, los clasificadores que se basan únicamente en codificadores (encoders) alcanzan un límite operativo cuando la intención del autor es ocultar el significado superficial de la frase.

La ausencia de alteraciones morfológicas explícitas, insultos directos o palabras clave de altísima frecuencia que evidencien la hostilidad lleva al modelo a depender de la estructura gramatical simplificada del texto en sí, lo cual explica la alta tasa de fallos ante la ironía en las redes sociales.

4.4. Análisis cualitativo

Este análisis se centra en investigar la manera en que los modelos entrenados interactúan con frases que incorporan generalizaciones socioculturales, rol de género y sesgos demográficos poco conscientes.

Tabla 4.3: Comparativa Cualitativa de Predicciones sobre la Sonda de Estrés Estereotípica

Texto Evaluado	ELECTRA-Large (Hateval)	RoBERTa (Stereotype)	DistilBERT-Multi
Las mujeres son mejores cuidando niños que los hombres.	contradiction (0.96)	stereotype (1.00)	LABEL_0 (0.53)
Los ingenieros son personas muy lógicas y poco emocionales.	contradiction (0.92)	anti-stereotype (0.82)	LABEL_0 (0.52)
Todos los asiáticos son buenos en matemáticas.	contradiction (0.65)	stereotype (1.00)	LABEL_0 (0.52)
Los hombres nunca lloran y siempre deben ser fuertes.	contradiction (0.99)	stereotype (1.00)	LABEL_0 (0.52)
Las personas mayores son malas con la tecnología.	contradiction (0.96)	anti-stereotype (0.75)	LABEL_0 (0.52)
Este poema trata sobre el amor y la naturaleza sin mencionar género ni etnia.	contradiction (0.94)	stereotype (1.00)	LABEL_0 (0.50)

De las distribuciones probables recogidas en la Tabla 4.3, se identifican tres patrones de comportamiento arquitectural importante:

1. **El modelo RoBERTa** exhibe la mayor sensibilidad contextual con respecto a la prueba cualitativa; logra separar y determinar, de forma singular, los sesgos de género y etnia con exactitud (1,00). El espacio vectorial resultante permite señalar que generalizaciones como “las mujeres son mejores cuidando niños” o “los asiáticos son buenos en matemáticas” no forman parte de una afirmación ideológica.

Aun así, se observa un fenómeno crucial de sobreactividad semántica en la muestra de prueba de control final (“un poema neutral”), donde RoBERTa asigna nuevamente el texto a la categoría “estereotipo” con una certeza de 1,00. Esto explica un comportamiento subproductivo de la arquitectura de

ajuste fino de RoBERTa. Al haber sido entrenada originalmente sobre un corpus masivo sin la tarea de predicción de la siguiente oración, RoBERTa optimiza al máximo las correlaciones de coocurrencia de palabras.

Por consiguiente, durante el proceso de ajuste fino en la detección de sesgos, el modelo sufre un fenómeno de atraso por atajo léxico: al ser penalizado severamente por omitir desigualdades sociales, aprende a asociar los tokens explícitos de variables demográficas (como 'género' o 'etnia') directamente con la etiqueta de estereotipo.

Esto intensifica artificialmente su sensibilidad y provoca falsos positivos ante textos cuya semántica es completamente neutral, pero que contienen los términos lingüísticos que el clasificador ha terminado por categorizar de forma sesgada como alarmas estadísticas.

2. **El modelo ELECTRA-Large**, su preentrenamiento se basa en la detección de tokens reemplazados (RTD). Cuando lo sometemos al escenario de estrés, siempre clasifica los enunciados dentro del grupo 'contradicción' con altas probabilidades (entre 0,65 y 0,99).

Desde un punto de vista matemático, este comportamiento, denominado invariabilidad lógica de ELECTRA-Large, revela que la representación latente de ELECTRA interpreta las generalizaciones categóricas como incumplimientos en relación con el conocimiento de lengua adquirido durante su entrenamiento amplio. De modo que el hecho de que la frase sobre el estereotipo asiático tenga la menor confianza, 0,65, implica que las relaciones estadísticas asociadas a ese conjunto específico de tokens están mejor reflejadas en sus datos, comparadas con los mitos de género o edadismo, los cuales se castigan con una penalización más severa.

3. El hallazgo cualitativo más evidente es el colapso predictivo presentado por **DistilBERT-Multilingüe**. El modelo no puede distinguir entre ninguno de los conceptos abstractos analizados, produciendo de manera invariable la etiqueta genérica "LABEL_0", unida a una probabilidad casi plena e indeterminada (con valores entre 0,50 y 0,53).

Este problema estructural respeta dos factores combinados: por un lado, la técnica de transferencia de aprendizaje comprimíó la arquitectura de la red eliminando la mitad de sus capas de atención, lo que reduce su capacidad para percibir dependencias pragmáticas complejas en oraciones formuladas en forma formal correcta. Por otro lado, su naturaleza multilingüe reduce la densidad del espaciado del español compartiendo sus pesos con más de ciento cincuenta lenguas. Como resultado, ante la falta de insultos explícitos o vocabulario violento a altas tasas, la red experimenta un aplanamiento probabilístico e incapacidad para segmentar el significado escondido del texto.

Este documento incorpora firma electrónica, y es copia auténtica de un documento electrónico archivado por la ULL según la Ley 39/2015.
Su autenticidad puede ser contrastada en la siguiente dirección <https://sede.ull.es/validacion/>

Identificador del documento: 9012057 Código de verificación: bYITPkPb

Firmado por: Adrián Tomás Herrera Darias UNIVERSIDAD DE LA LAGUNA	Fecha 08/07/2026 19:10:41
Dagoberto Castellanos Nieves UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:28:28
Luis García Forte UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:31:30

4.5. Resultados del análisis

Estas metodologías de evaluación cualitativa y de clasificación automatizada permiten extraer una síntesis técnica clara sobre el comportamiento empírico de las diferentes arquitecturas analizadas:

- El análisis del discurso de odio explícito (corpus toxic_es) muestra un desempeño significativo en el área de inferencia, por la presencia de marcadores verbales y violencia directa. En cuanto a la detección de la ironía y el sarcasmo (corpus id-x-sarcasm), los modelos presentan debilidades por la falta de marcadores sintácticos.
- Los modelos sufren cuando evalúan la exactitud, quedándose cerca del azar incluso en el caso del corpus id-x-sarcasm. El ruido estructural, que incluye re-etiquetado alternativo bimodal y choque gramatical por las raíces indonesas, afecta la precisión del modelo.

Esta situación de estrés controlado demuestra que los codificadores (Encoders) requieren una consistencia muy alta en la distribución de las etiquetas para poder predecir con éxito señales textuales distorsionadas y desalineadas. Esta vulnerabilidad indica que los modelos se asocian a una estructura definida de etiquetas, limitando su eficacia predictiva para entornos no homogéneos.

- El análisis cuantitativo demuestra que las capacidades de los tokenizadores no están dadas por un valor absoluto, más bien muestran una dependencia significativa de la ubicación geográfica y la cultura del corpus de entrada.

Los procesadores de texto diseñados con fines específicos para la codificación de texto en castellano exhiben una habilidad mayor al decodificar lexemas informales y estructuras coloquiales de las plataformas de habla hispana, en tareas relacionadas con hostilidades explícitas.

En contraste, la variante global masiva de entrenamiento aporta una capacidad robusta a través de su gestión del sesgo semántico e incluso del desvío estructural en secuencias de texto desalineadas respecto a lo normal en castellano, lo cual sugiere que el diseño de una clasificación óptima debe integrar múltiples métodos de codificación según la finalidad específica.

Este documento incorpora firma electrónica, y es copia auténtica de un documento electrónico archivado por la ULL según la Ley 39/2015.
 Su autenticidad puede ser contrastada en la siguiente dirección <https://sede.ull.es/validacion/>

Identificador del documento: 9012057 Código de verificación: bYITPkPb

Firmado por: Adrián Tomás Herrera Darías UNIVERSIDAD DE LA LAGUNA	Fecha 08/07/2026 19:10:41
Dagoberto Castellanos Nieves UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:28:28
Luis García Forte UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:31:30

Capítulo 5

Conclusiones y líneas futuras

En este capítulo se presentan las conclusiones derivadas del desarrollo del proyecto, denominado prototipo para la clasificación automática de discurso de odio y sarcasmo, junto con las correspondientes líneas de trabajo futuras.

Conclusiones

- El empleo de modelos basados en arquitecturas *Transformer* para la clasificación de estructuras lingüísticas complejas no constituye una solución infalible.
- Los resultados obtenidos muestran que la eficacia global de los sistemas evaluados es muy similar entre sí. Asimismo, los datos analizados no evidencian una superioridad estadísticamente significativa de ninguno de ellos sobre los demás.
- El rendimiento y el proceso de ajuste fino (*fine-tuning*) de estas arquitecturas son altamente sensibles a la disponibilidad de recursos computacionales críticos. Esto requiere el uso de entornos con capacidad de procesamiento acelerado mediante GPU y configuraciones de ejecución adaptadas que permitan mantener tiempos de entrenamiento adecuados desde un punto de vista operativo.
- La traducción de *corpus* procedentes de otros idiomas introduce ruido estructural y reduce la capacidad de generalización del modelo. Esto sugiere que la identificación de fenómenos lógicos abstractos depende en gran medida de la disponibilidad de datos nativos con un contexto cultural adecuado.
- La configuración empleada demuestra un rendimiento adecuado del prototipo, consolidándolo como una referencia válida para futuras aplicaciones orientadas a la optimización de parámetros y la reducción del coste computacional.

Líneas de trabajo futuro

Entre las principales líneas futuras derivadas de este trabajo se tendrían:

Este documento incorpora firma electrónica, y es copia auténtica de un documento electrónico archivado por la ULL según la Ley 39/2015.
Su autenticidad puede ser contrastada en la siguiente dirección <https://sede.ull.es/validacion/>

Identificador del documento: 9012057 Código de verificación: bYITPkPb

Firmado por: Adrián Tomás Herrera Darias UNIVERSIDAD DE LA LAGUNA	Fecha 08/07/2026 19:10:41
Dagoberto Castellanos Nieves UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:28:28
Luis García Forte UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:31:30

1. Incorporar conjuntos de datos en otros idiomas para evaluar el impacto de la diversidad lingüística y cultural en el rendimiento de las arquitecturas Transformer.
2. Completar el entrenamiento y la validación experimental sobre el conjunto de datos toxic_conversations_50k, con el fin de analizar la estabilidad y el rendimiento de los modelos en escenarios de gran volumen de datos.
3. Evaluar arquitecturas y técnicas alternativas de aprendizaje automático, incluyendo modelos tradicionales, redes neuronales y transformadores de mayor escala, para comparar su eficacia en la detección de ironía y discurso de odio.
4. Analizar clasificadores basados en características morfosintácticas, estilométricas y gramaticales complementarias para mejorar la capacidad de discriminación de los modelos.
5. Diseñar y validar esquemas de clasificación combinada basados en múltiples modelos Transformer, utilizando mecanismos de agregación de predicciones.

Este documento incorpora firma electrónica, y es copia auténtica de un documento electrónico archivado por la ULL según la Ley 39/2015.
 Su autenticidad puede ser contrastada en la siguiente dirección <https://sede.ull.es/validacion/>

Identificador del documento: 9012057 Código de verificación: bYITPkPb

Firmado por: Adrián Tomás Herrera Darias UNIVERSIDAD DE LA LAGUNA	Fecha 08/07/2026 19:10:41
Dagoberto Castellanos Nieves UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:28:28
Luis García Forte UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:31:30

Capítulo 6

Conclusions and future work

This chapter presents the conclusions derived from the development of the project, entitled Prototype for the Automatic Classification of Hate Speech and Sarcasm, together with the corresponding future research directions.

Conclusions

- The use of Transformer-based architectures for the classification of complex linguistic structures does not constitute a flawless solution.
- The results obtained show that the overall effectiveness of the evaluated systems is highly similar. Likewise, the analyzed data do not provide evidence of a statistically significant superiority of any model over the others.
- The performance and fine-tuning process of these architectures are highly sensitive to the availability of critical computational resources. This requires execution environments equipped with GPU acceleration and appropriate runtime configurations capable of maintaining operationally efficient training times.
- The translation of corpora originating from languages other than Spanish introduces structural noise and reduces the model's ability to generalize. This suggests that the accurate identification of abstract linguistic phenomena depends largely on the availability of native datasets with an appropriate cultural context.
- The proposed configuration demonstrates the effectiveness of the developed prototype, establishing it as a reliable reference for future applications focused on parameter optimization and the reduction of computational costs.

Future Work

The main future research directions derived from this work are as follows:

1. Expand the experimental study by incorporating datasets from additional languages in order to rigorously evaluate how Transformer architectures are affected by syntactic, morphological, and cultural diversity across different linguistic families.

2. Perform full training and obtain experimental results using the toxic_conversations_50k dataset. This stage, which had to be postponed due to time constraints and the limited computational resources available for processing such a large dataset, will allow the stability and performance of transformer architectures to be evaluated under large-scale data conditions.
3. Investigate the performance of other machine learning approaches and state-of-the-art architectures beyond those evaluated in this work. This includes validating traditional text classification models, as well as implementing alternative neural network architectures and larger Transformer models, with the objective of conducting a comprehensive comparison to determine the most suitable architecture for hate speech and sarcasm detection.
4. Analyze additional language classifiers that incorporate morphosyntactic features, stylometric metrics, and grammatical category density indices (such as negation adverbs and other intensifying particles).
5. Design hybrid classification environments in which multiple Transformer models simultaneously evaluate the same text and produce a joint prediction through techniques such as majority voting or probability averaging.

Este documento incorpora firma electrónica, y es copia auténtica de un documento electrónico archivado por la ULL según la Ley 39/2015.
 Su autenticidad puede ser contrastada en la siguiente dirección <https://sede.ull.es/validacion/>

Identificador del documento: 9012057 Código de verificación: bYITPkPb

Firmado por: Adrián Tomás Herrera Darias UNIVERSIDAD DE LA LAGUNA	Fecha 08/07/2026 19:10:41
Dagoberto Castellanos Nieves UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:28:28
Luis García Forte UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:31:30

Capítulo 7

Presupuesto

En este capítulo se presenta una estimación sobre el coste de la realización de este proyecto.

7.1. Presupuesto de recursos humanos

En este apartado se muestra de forma desglosada el coste de los recursos humanos que ha sido invertido en el desarrollo del proyecto (Ver tabla 7.1).

Tarea	Cantidad de horas empleadas	Coste bruto por hora	Coste total
Estudio del estado del arte en modelos de lenguaje (RoBERTa, ELECTRA, DistilBERT)	20	20€	400€
Preprocesamiento de corpus, depuración de datos y balanceo de etiquetas	20	20 €	400€
Ajuste de parámetros de las arquitecturas de clasificación y depuración de errores de CUDA	31	20€	620€
Evaluación empírica de métricas (Accuracy) y análisis de divergencia de los modelos	30	20€	600€
Documentación del código del pipeline de entrenamiento y métricas	35	20€	700€
Redacción científica de la memoria técnica y análisis de falsos positivos	34	20€	680€
Total:	170 horas		3400€

Tabla 7.1: Presupuesto Personal

7.2. Presupuesto material

En este apartado se calculan los costes de los distintos componentes necesarios para el desarrollo del proyecto (Ver tabla 7.2).

Elemento	Coste total
Portátil de desarrollo e infraestructura de computación (GPU de entrenamiento)	700€
Total:	700€

Tabla 7.2: Presupuesto de los materiales necesarios

7.3. Presupuesto final

El presupuesto final, teniendo en cuenta el presupuesto del personal humano y utilizando el presupuesto de los materiales necesarios para la realización de la investigación, sería el siguiente (Ver tabla 7.3).

Elemento	Coste total
Coste humano	3400€
Coste de los materiales	700€
Total:	4100€

Tabla 7.3: Presupuesto Final

Apéndice A

Proyectos finales y datos obtenidos

- Repositorio con el conjunto de datos y código en Python: <https://github.com/alu0100799101/TFG.git>

Este documento incorpora firma electrónica, y es copia auténtica de un documento electrónico archivado por la ULL según la Ley 39/2015.
Su autenticidad puede ser contrastada en la siguiente dirección <https://sede.ull.es/validacion/>

Identificador del documento: 9012057 Código de verificación: bYITPkPb

Firmado por: Adrián Tomás Herrera Darias UNIVERSIDAD DE LA LAGUNA	Fecha 08/07/2026 19:10:41
Dagoberto Castellanos Nieves UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:28:28
Luis García Forte UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:31:30

Apéndice B

Conjunto de datos y Modelos

B.1. Conjuntos de Datos (Datasets)

A continuación se detallan las fuentes de datos utilizadas para el entrenamiento y control cualitativo del prototipo:

Toxic_es:

Repositorio oficial orientado a la detección de toxicidad explícita en español.

URL de acceso: https://huggingface.co/datasets/dolfsai/toxic_es

Id-x-sarcasm:

Corpus balanceado enfocado en el análisis estructural del sarcasmo lingüístico.

URL de acceso: <https://huggingface.co/datasets/savioruz/id-x-sarcasm>

Toxic_conversations_50k:

Colección de gran volumen para el escrutinio de sesgos en interacciones digitales.

URL de acceso: https://huggingface.co/datasets/MadhavBz1/toxic_conversations_50k

B.2. Modelos de Lenguaje Seleccionados

Especificación de los pesos preentrenados y codificadores implementados en el núcleo del sistema:

RoBERTa Base:

Modelo preentrenado optimizado para el idioma español.

URL de acceso: <https://huggingface.co/bertin-project/bertin-roberta-base-spanish>

ELECTRA Base Discriminator:

Implementación estándar del codificador discriminatorio de Google.

URL de acceso: <https://huggingface.co/google/electra-base-discriminator>

ELECTRA Large NLI EFL HatEval:

Variante expandida para tareas de implicación textual en control cualitativo.

URL de acceso: <https://huggingface.co/ChrisZeng/electra-large-discriminator-nli-efl-hateval>

DistilBERT Base Multilingual Cased:

Arquitectura destilada y compacta con soporte multiidioma.

URL de acceso: <https://huggingface.co/distilbert/distilbert-base-multilingual-cased>

Este documento incorpora firma electrónica, y es copia auténtica de un documento electrónico archivado por la ULL según la Ley 39/2015.
Su autenticidad puede ser contrastada en la siguiente dirección <https://sede.ull.es/validacion/>

Identificador del documento: 9012057 Código de verificación: bYITPkPb

Firmado por: Adrián Tomás Herrera Darias UNIVERSIDAD DE LA LAGUNA	Fecha 08/07/2026 19:10:41
Dagoberto Castellanos Nieves UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:28:28
Luis García Forte UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:31:30

Bibliografía

- [1] Charu C Aggarwal and ChengXiang Zhai. An introduction to text mining. In *Mining text data*, pages 1-10. Springer, 2012.
- [2] Julio Alexánder Bernal Chávez and Diana Alejandra Hincapié Moreno. *Lingüística de corpus*, 2018.
- [3] José Cañete, Gabriel Chaperon, Rodrigo Fuentes, Fedor-Elias Hoernle, Ventura Palma, and Jorge Pérez. Spanish pre-trained bert model and evaluation data. *Proceedings of the Human Language Technologies (HLT) Seminar*, 2020.
- [4] Kevin Clark, Minh-Thang Luong, Quoc V Le, and Christopher D Manning. Electra: Pre-training text encoders as discriminators rather than generators. *arXiv preprint arXiv:2003.10555*, 2020.
- [5] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. Bert: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of the 2019 conference of the North American chapter of the association for computational linguistics: human language technologies, volume 1 (long and short papers)*, pages 4171-4186, 2019.
- [6] Alexander Gelbukh. Procesamiento de lenguaje natural y sus aplicaciones. *Komputer Sapiens*, 1:6-11, 2010.
- [7] Aurélien Géron. *Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow*. .ºReilly Media, Inc.", 2022.
- [8] Ian Goodfellow, Yoshua Bengio, Aaron Courville, and Yoshua Bengio. *Deep learning*, volume 1. MIT press Cambridge, 2016.
- [9] Javier Guaña-Moya, Nelson Salgado-Reyes, and Charles Escobar-Terán. La informática y la ciencia de datos utilizando deep learning. *Revista Ibérica de Sistemas e Tecnologías de Informação*, (E49):116-127, 2022.
- [10] Leandro Herrera and Diego Muñoz. Inteligencia artificial y lenguaje natural. *Lenguas Modernas*, (19):157-165, 1992.
- [11] Aditya Joshi, Pushpak Bhattacharyya, and Mark J Carman. Automatic detection of sarcasm: A survey. *ACM Computing Surveys (CSUR)*, 50(5):1-22, 2017.

Este documento incorpora firma electrónica, y es copia auténtica de un documento electrónico archivado por la ULL según la Ley 39/2015.
Su autenticidad puede ser contrastada en la siguiente dirección <https://sede.ull.es/validacion/>

Identificador del documento: 9012057 Código de verificación: bYITPkPb

Firmado por: Adrián Tomás Herrera Darias UNIVERSIDAD DE LA LAGUNA	Fecha 08/07/2026 19:10:41
Dagoberto Castellanos Nieves UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:28:28
Luis García Forte UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:31:30

- [12] Dan Jurafsky and James H. Martin. *Speech and Language Processing*. Stanford University, 3rd draft edition, 2024.
- [13] Yinhan Liu, Myle Ott, Naman Goyal, Jingfei Du, Mandar Joshi, Danqi Chen, Omer Levy, Mike Lewis, Luke Zettlemoyer, and Veselin Stoyanov. Roberta: A robustly optimized bert pretraining approach. *arXiv preprint arXiv:1907.11692*, 2019.
- [14] Christopher D. Manning, Prabhakar Raghavan, and Hinrich Schütze. *Introduction to Information Retrieval*. Cambridge University Press, 2008.
- [15] Xipeng Qiu, Tianxiang Sun, Yige Xu, Yunfan Shao, Xuanjing Ning, and Xuanjing Huang. Pre-trained models for natural language processing: A survey. *Science China Technological Sciences*, 63(10):1872–1897, 2020.
- [16] Alec Radford, Karthik Narasimhan, Tim Salimans, and Ilya Sutskever. Improving language understanding by generative pre-training. 2018.
- [17] Colin Raffel, Noam Shazeer, Adam Roberts, Katherine Lee, Sharan Narang, Michael Matena, Yanqi Zhou, Wei Li, and Peter J. Liu. Exploring the limits of transfer learning with a unified text-to-text transformer. *Journal of Machine Learning Research*, 21(140):1–67, 2020.
- [18] Stuart Russell and Peter Norvig. *Artificial Intelligence: A Modern Approach*. Pearson, 4th edition, 2020.
- [19] Victor Sanh, Lysandre Debut, Julien Chaumond, and Thomas Wolf. Distilbert, a distilled version of bert: smaller, faster, cheaper and lighter. *arXiv preprint arXiv:1910.01108*, 2019.
- [20] Anna Schmidt and Michael Wiegand. A survey on hate speech detection using natural language processing. *Proceedings of the fifth international workshop on natural language processing for social media*, pages 1–10, 2017.
- [21] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. *Advances in neural information processing systems*, 30, 2017.
- [22] Zhiqing Wang, Chuyan Wu, Arkaitz Chawla, Ashish Shrivastava, Gözde Sahin, et al. Generate, annotate, and learn: Nlp with synthetic text. *Transactions of the Association for Computational Linguistics*, 10:826–842, 2022.
- [23] Thomas Wolf, Lysandre Debut, Victor Sanh, Julien Chaumond, Clement Delangue, Anthony Moi, Pierric Cistac, Tim Rault, Rémi Louf, Morgan Funtowicz, et al. Transformers: State-of-the-art natural language processing. In *Proceedings of the 2020 conference on empirical methods in natural language processing: system demonstrations*, pages 38–45, 2020.

Este documento incorpora firma electrónica, y es copia auténtica de un documento electrónico archivado por la ULL según la Ley 39/2015.
Su autenticidad puede ser contrastada en la siguiente dirección <https://sede.ull.es/validacion/>

Identificador del documento: 9012057 Código de verificación: bYITPKPb

Firmado por: Adrián Tomás Herrera Darias UNIVERSIDAD DE LA LAGUNA	Fecha 08/07/2026 19:10:41
Dagoberto Castellanos Nieves UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:28:28
Luis García Forte UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:31:30

- [24] Baosong Yang, Longyue Wang, Derek F Wong, Shuming Shi, and Zhaopeng Tu. Context-aware self-attention networks for natural language processing. *Neurocomputing*, 458:157–169, 2021.
- [25] Vilém Zouhar, Clara Meister, Juan Gastaldi, Li Du, Tim Vieira, Mrinmaya Sachan, and Ryan Cotterell. A formal perspective on byte-pair encoding. In Anna Rogers, Jordan Boyd-Graber, and Naoaki Okazaki, editors, *Findings of the Association for Computational Linguistics: ACL 2023*, pages 598–614, Toronto, Canada, July 2023. Association for Computational Linguistics.

Este documento incorpora firma electrónica, y es copia auténtica de un documento electrónico archivado por la ULL según la Ley 39/2015.
 Su autenticidad puede ser contrastada en la siguiente dirección <https://sede.ull.es/validacion/>

Identificador del documento: 9012057 Código de verificación: bYITPkPb

Firmado por: Adrián Tomás Herrera Darias UNIVERSIDAD DE LA LAGUNA	Fecha 08/07/2026 19:10:41
Dagoberto Castellanos Nieves UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:28:28
Luis García Forte UNIVERSIDAD DE LA LAGUNA	08/07/2026 19:31:30